

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
"НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК**

Малкова Екатерина Евгеньевна

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
НАРРАТИВЫ ПРЕСТИЖНОСТИ И ДОСТУПНОСТИ ВЫСШЕГО
ОБРАЗОВАНИЯ В МОСКОВСКИХ ВУЗАХ (НА ПРИМЕРЕ ПУБЛИКАЦИЙ В
НОВОСТНЫХ СООБЩЕСТВАХ ВКОНТАКТЕ ЗА 2020–2025 ГГ.)**

**NARRATIVES OF THE PRESTIGE AND ACCESSIBILITY OF HIGHER
EDUCATION IN MOSCOW UNIVERSITIES (BASED ON PUBLICATIONS IN
VKONTAKTE NEWS COMMUNITIES IN 2020–2025)**

по направлению подготовки 01.04.02 Прикладная математика и информатика
образовательная программа «Аналитика больших данных»

Студент

Е.Е. Малкова

Научный руководитель
Преподаватель ДБДИП ФКН
НИУ ВШЭ

М.В. Бакшук

Москва, 2026

Оглавление

Оглавление	1
Аннотация	3
Ключевые слова	3
Введение	4
1. Теоретико-методологические подходы к изучению нарративов престижности и доступности в медиадискурсе о высшем образовании	7
1.1. Введение	7
1.2. Теоретическая рамка исследования	7
1.2.1. Высшее образование как социальный институт	7
1.2.2. Доступность высшего образования: барьеры	9
1.2.3. Престижность высшего образования в общественном восприятии	13
1.2.4. Нарративы в медиа и конструирование социальной реальности	15
1.3. Методологические подходы к работе с текстовой информацией	17
1.3.1. Специфика предобработки текстов из социальных сетей	17
1.3.2. Поиск смыслов: векторизация и вычислительная семантика	19
1.3.3. Инструменты обнаружения нарративов: от чисел к темам	20
1.3.4. Поиск мнений и оценка тональности	21
1.3.5. Валидация	21
2. Методология исследования. Сбор и предобработка информационной базы исследования	23
2.1. Методологические основания исследования	23
2.1.1. Определение ключевых понятий	23
2.1.2. Цель исследования	23
2.1.3. Задачи исследования	23
2.1.4. Основные гипотезы исследования	24
2.1.5. Теоретический объект исследования	24
2.1.6. Предмет исследования	24
2.1.7. Эмпирический объект исследования	24
2.1.8. Обоснование выбора платформенного решения как источника данных	24
2.1.9. Обоснование выбора временного периода для сбора данных	25
2.1.10. Логика отбора популярных сообществ для анализа	26
2.1.11. Получение ключей доступа	27

2.1.12. Алгоритм парсинга публикаций сообществ	28
2.1.13. Алгоритм парсинга комментариев к публикациям сообщества	29
2.2. Разведочный анализ данных	30
2.2.1. Описание данных	30
2.2.2. Предобработка данных публикаций	38
2.2.3. Предобработка данных комментариев и их анализ.....	39
3. Анализ данных	43
3.1. Нарративная структура университетской коммуникации	43
3.1.1. Сравнение нарративных классов	43
3.1.2. Оценка качества автоматической разметки.....	45
3.1.3. Семантическая проверка смешанного нарративного класса.....	46
3.2. Тематико-контекстный анализ корпуса	47
3.2.1. Тематическое моделирование LDA и контекст доступности высшего образования	47
3.2.2. Анализ контекстного окружения ключевых слов (KWIC)	49
3.3. Диагностическое моделирование содержательного отклика.....	50
3.3.1. Базовое решение и метрики качества	50
3.3.2. Продвинутое решение и метрики качества.....	55
3.4. Выводы из анализа данных.....	60
Заключение	63
Список использованных источников и литературы	66
Приложения	71
Приложение А. Ссылка на исследовательский репозиторий.	71
Приложение Б. Список источников данных – сообществ университетов г. Москвы.	71
Приложение В. Перечень новостных сообщество вузов, включенных в эмпирический корпус исследования.	72
Приложение Г. Словари маркеров социальной доступности и престижности.	73
Приложение Д. Использованные модели и библиотеки.	74
Приложение Е. Словари позитивных и негативных маркеров.....	74

Аннотация

Социальные феномены из СМИ формируют общественные представления – нарративы, участвующие в конструировании реальности. Столичные вузы часто называют более престижными и менее доступными, наделяя их свойствами труднодоступного блага, обладание которым наделяет индивида особым статусом.

Данная работа посвящена изучению смысловых механизмов, через которые в медиадискурсе формируется образ высшего образования в Москве, как престижного и/или социально доступного. Эмпирическую базу исследования составили публикации официальных университетских сообществ за 2020-2025 гг. и комментарии пользователей к ним. Для анализа использованы методы обработки текстовой информации: словарная разметка нарративов престижности и доступности, тематическое моделирование LDA, анализ контекстного окружения ключевых слов, оценка тональности, ручная валидация разметки и модели машинного обучения для выявления признаков, ассоциируемых с высоким содержательным откликом.

Анализ показал, что в коммуникации московских университетов преобладает нарратив престижности, связанный с рейтингами, научными достижениями, карьерными перспективами, международным сотрудничеством и экспертностью. Нарратив социальной доступности представлен менее автономно и чаще пересекается с престижностью; он связан с приемной кампанией, бюджетными местами, стоимостью обучения, общежитием, льготами, информационной поддержкой. Анализ комментариев показал, что тема доступности в пользовательской реакции приобретает более проблемный характер: аудитория обсуждает стоимость обучения, условия поступления, общежития, баллы и другие барьеры. Публикации о доступности чаще сопровождаются содержательными и вопросительными комментариями, тогда как престижность выполняет преимущественно имиджевую функцию. Построенные модели выявляют ассоциативные связи между темой публикации, нарративной рамкой, источником, форматом коммуникации и высоким содержательным откликом.

Ключевые слова

Высшее образование, престижность, социальная доступность, сообщества университетов, «ВКонтакте», нарративный анализ, социальные медиа, комментарии, публикации, пользовательская вовлеченность, барьеры доступности.

Введение

Изучение элитарности и неравного доступа к образовательному процессу в России активно привлекают внимание исследователей в различных сферах: социологии, демографии, политологии и государственного управления. Такое разнообразие исследовательских модальностей отражает социальную значимость роли высшего образования в развитии современного общества. Высшее образование является мощным социальным лифтом, что делает его объектом наблюдения во многих социальных науках, позволяя исследовать реальные возможности вертикальной и горизонтальной мобильности среди разных групп населения. Абитуриенты при выборе университета исходят не только из собственных образовательных возможностей, но и из не менее важных характеристик вузов, помимо качества самого образования – их репутации, доступности, престижности. В ситуации интенсивной конкуренции за места в лучших вузах, важным становится то, какой медиадискурс формируется вокруг высшего образования, поскольку в нем выделяются некоторые коллективные представления и нарративы об обучении, которые в свою очередь влияют на проектирование образовательных маршрутов абитуриентами.

Наиболее доступными каналами коммуникации вузов с абитуриентами являются социальные сети. В настоящее время их роль в публичной коммуникации университетов и формировании представлений о высшем образовании возрастает. Официальные университетские сообщества создают определенные средовые условия для вовлечения выпускников путем публикации разнообразного контента об образовательных возможностях вуза, его технологической обеспеченности, развитой сети студенческих и карьерных сообществ, а также об академических успехах. Сообщества выступают не только каналом информирования абитуриентов, но и пространством репрезентации институционального образа университета. Все это способствует формированию определенных представлений о престиже и доступности обучения в конкретном учебном заведении. Эти представления напрямую влияют на решения относительно образовательной траектории молодежи. Примечательно, что официальные представительства университетов в социальных сетях преследуют цели создания позитивного образа своего бренда. Однако, существующие в реальности недостатки упускаются из информационного поля. С репрезентацией этой части образовательного процесса справляются пользовательские обсуждения в комментариях и неофициальных группах об образовании.

Исследовательское сообщество отмечает важность мониторинга «сетевых СМИ и тематических групп в социальных сетях» для минимизирования и своевременной реакции на

возникновение «репутационных или имиджевых рисков вуза, которые могут быть связаны с негативной тональностью упоминания вуза в социальных сетях» [29]. Для этого существуют специализированные платформы, которые помогают проводить мониторинг – отслеживание информации об интересующем объекте, ее структурирование и анализ –, А.В. Прохоров относит к таким сервисы обратной связи, социальные сети, блоги, форумы и тематические сайты, помимо платформ, осуществляющих машинный мониторинг, например, YouScan, BrandAnalytics и другие [29]. Исследователи прибегают к использованию данных, собранных агрегирующими платформами, либо осуществляют самостоятельный поиск и сбор данных для анализа упоминаний аспектов, связанных с образовательным процессом. В 2021 году агентством Sidorin Lab был составлен рейтинг вузов г. Москвы, базирующийся на тональности упоминаний университетов в социальных медиа, что примечательно, социальная сеть «ВКонтакте» стала лидером среди источников репутационной информации [29]. Можно отметить, что в рамках количественных исследований упоминаний вузов, проведение мониторинга и извлечение данных из социальной сети «ВКонтакте» получает распространение [34] в последние годы, конкурируя и постепенно вытесняя качественные подходы к проведению исследований. В условиях сохраняющегося неравенства образовательных возможностей особенно значимым становится анализ того, как в медиадискурсе соотносятся престижность и социальная доступность высшего образования. Обращение к публикациям и комментариям «ВКонтакте» позволяет рассмотреть не только то, какой образ образования транслируется университетами, но и какие вопросы, ожидания и барьеры проявляются в пользовательской реакции.

Исходя из этого, исследовательский вопрос работы звучит следующим образом: каков механизм формирования представлений о престижности и социальной доступности высшего образования в московских вузах на основе медианарративов, транслируемых в новостных сообществах социальных медиа в течение периода с 2020 по 2025 год?

Работа состоит из нескольких структурированных глав. Первая глава обозревает теоретические подходы к изучению нарративов престижности и доступности в медиадискурсе о высшем образовании, а также методологические подходы к работе с текстовой информацией.

Во второй главе определяется методология исследования, а также описывается механизм сбора и предобработки информационной базы исследования. Для формирования базы данных был использован метод парсинга текстовых публикаций из новостных сообществ социальной сети «ВКонтакте». Третья глава посвящена анализу сконструированной базы публикаций с

использованием инструментов автоматической обработки естественного языка, машинного обучения; описываются результаты анализа.

Исследование сталкивается с некоторыми ограничениями, которые следует принимать во внимание при интерпретации полученных результатов. Анализ медиадискурса вокруг высшего образования сконцентрирован на одной социальной сети, что оставляет неизвестным специфику нарративов, формирующихся на других платформах (которые не рассматриваются ввиду меньшей популярности среди пользователей или новых законодательных ограничений), и исключает возможность сравнения нарративов между различными платформами. Фокус на определенном временном периоде ограничивает возможность рассмотрения трансформации нарративов об образовании в медиадискурсе в динамике. Репрезентативность результатов ограничена географическим фокусом исследования на университетах Москвы: это позволяет сконцентрировать анализ вокруг общественных представлений о престижности и доступности высшего образования в одном из крупнейших образовательных центров страны (и, конечно, федеральном центре), опираясь на публикации федеральных и локальных городских сообществ. В рамках анализа комментариев стоит отметить, что как правило, крупные сообщества имеют развитую систему управления им, включающую в себя модерацию комментариев, в связи с чем некоторые неудобные или резкие реакции могут быть удалены, что искажает общую суть обсуждения. Кроме того, автоматическая разметка нарративов и признаков рассматривается по результатам ручной валидации части корпуса как *weak labelling* – приближенные индикаторы, а не безошибочно определенные признаки. Наконец, модели содержательного отклика имеют преимущественно диагностический характер, поэтому результаты моделирования интерпретируются как ассоциативные связи, а не как надежное предсказание поведения пользователей.

1. Теоретико-методологические подходы к изучению нарративов престижности и доступности в медиадискурсе о высшем образовании

1.1. Введение

Обзор литературы концептуально состоит из двух частей – теоретической и методологической. Теоретический обзор состоит из следующих разделов: в первом отмечается роль образования в процессе социализации, а также оценивается значимость получения высшего образования в современном обществе; во втором рассматриваются как сами барьеры доступности высшего образования, с которыми сталкиваются абитуриенты, так и роль их репрезентации в СМИ; в третьем раскрывается общественное восприятие престижности вуза, его роль в воспроизводстве символического капитала и социального неравенства в образовательной среде; в четвертом – поясняется природа нарратива как социальной структуры, конструирующей саму реальность, формирующей общественные представления и таким образом воздействующей на идентичность и действия людей.

Методологический обзор состоит из следующих разделов: в первом очерчиваются особенности текстов социальных сетей как источника данных, а также обозначается важность предобработки таких данных; во втором исследуется применимость векторизации и вычислительной семантики как промежуточного этапа обработки и анализа текстовых данных; в третьем рассматриваются более продвинутые инструменты, с помощью которых можно предпринять попытку обнаружения нарративов в текстовом корпусе.

1.2. Теоретическая рамка исследования

1.2.1. Высшее образование как социальный институт

Социализация является неотъемлемым и фундаментальным процессом в жизни современного человека, она посвящена приобщению личности к социальному опыту, коллективной истории и устоявшимся нормам и ценностям, характерным для конкретного общества. Основной функцией данного процесса является непосредственная интеграция индивидов в общество для их дальнейшего продуктивного существования в нем. В соответствии с познаниями социологической теории, процесс социализации можно условно разделить на две стадии – первичную и вторичную социализацию.

Первичная социализация отвечает за научение ребенка базовым знаниям о мире и правилах существования в обществе, коммуникации с другими индивидами, а также ценностям и нормам среды. Семья и дошкольные учреждения, являясь основными агентами первичной социализации ребенка, так называемыми «значимыми другими», формируют его ролевые

модели взаимодействия с миром, как и саму объективность этого мира [44].

Если первичная социализация затрагивает довольно ранний этап развития ребенка, его детство и юношеские годы, то вторичная социализация уже связывается с дальнейшими, более взрослыми этапами его жизни. Социализация в целом – стихийный процесс, он протекает на протяжении всего периода жизнедеятельности индивида, может происходить множество раз в зависимости от смены обстоятельств и жизненного пути, таким образом помогая человеку адаптироваться к новой реальности. В рамках вторичной социализации характерно некоторое интернализирование сформированных в детстве обществ-миров и соответствующих им социальных ролей [15]. Помимо усвоения новых навыков, происходит также некоторое переосмысление (а параллельно – и актуализация) предыдущего опыта и устаревших моделей поведения, более неактуальных социальной действительности. Среди множества социальных институтов, способствующих успешной социализации, можно особо отметить институт образования в лице государственных образовательных учреждений, поскольку именно они являются неотъемлемым и основополагающим этапом в становлении личности [10].

Получение образования способствует расширению кругозора, приобретению знаний об устройстве мира и жизни в обществе. Важность образования осознается и закрепляется на государственном уровне. Так, в Российской Федерации начальное общее, основное общее и среднее общее образование являются обязательными для всех граждан государства, что закреплено законодательными актами. В современном мире получение образования более высоких ступеней или профилей является также и мощным социальным лифтом, который способствует развитию карьерного пути и обеспечивает индивида широкой вариативностью при выборе дальнейшей профессии.

Высшее образование представляется особой средой для передачи специализированных профессиональных навыков и знаний. В университете знания передаются от опытных преподавателей, имеющих актуальные навыки для развития в профессии, а соревновательная среда способствует большей гибкости и заинтересованности в обучении среди студентов. Считается, что существует народный «устоявшийся» путь развития – «детский сад – школа – университет – работа» [9] –, в котором после окончания высшего учебного заведения происходит некоторый перелом, связанный со вступлением в истинно взрослую жизнь, где человек ощущает и ведет себя соответственно.

Наряду с получением документа, подтверждающего квалификацию специалиста, высшее образование способствует развитию компетенций и навыков, помогающих и в обычной жизни,

таких как критическое мышление, способность к изучению и анализу новой информации и прочие. Выпускники высших образовательных учреждений имеют сравнительное конкурентное преимущество на рынке труда [14], так, по результатам расчета рейтинга лучших вузов России RAEX-100 за 2025 год [1], работодатели предпочитают выпускников следующих учебных заведений: МГТУ им. Н.Э. Баумана, РАНХиГС, МГУ имени М.В. Ломоносова, РЭУ им. Г.В. Плеханова, НИУ ВШЭ, МГИМО МИД России, УрФУ, МФТИ, ФУ при Правительстве РФ, СПбГУ и другие, менее популярные вузы. Таким образом, университет можно назвать воспроизводителем социального неравенства, поскольку в зависимости от названия учебного заведения, специализации и оценок в дипломе людям открываются разные карьерные перспективы [14].

Интересно отметить, что высшее образование в современной России начинает в некоторой степени обесцениваться [14], уже недостаточно иметь звание выпускника уважаемого вуза, важны навыки, которыми человек в действительности обладает. Например, молодые юноши выбирают образование в том числе и исходя из нежелания проходить военную службу по призыву – становясь студентами более «слабых» («нишевых») университетов, чтобы формально числиться среди учащихся вуза и получить отсрочку от армии [18], по факту будучи не заинтересованными в самом обучении и приобретаемых компетенциях.

Несмотря на стремительную трансформацию, институт образования по-прежнему «остаётся одним из самых доступных каналов социальной мобильности» [43], поскольку требует меньших ресурсов входа – связей, стартового капитала или исключительных навыков.

1.2.2. Доступность высшего образования: барьеры

Образование – есть общественно значимое благо [40]. В современных реалиях оно трансформировалось в квазиобщественное благо, поскольку ему присущи черты как общественного, так и частного блага [7]. Образование в качестве общественного блага предполагает его всеобщую доступность для граждан на безвозмездной основе, а в качестве частного блага – ограниченную доступность посредством платы за оказание образовательных услуг.

В поздние годы существования Российской Империи в учебных заведениях создавалась гомогенная среда, внушающая «принадлежность к определенному классу» [4], что в свою очередь обеспечивало единообразное воспитание студентов в одном направлении – идеологическом и классовом [4].

Образование в целом было доступно немногим, а лишь достойным гражданам общества,

которые родились в знатных и богатых семьях, в то время как менее обеспеченные слои общества были вынуждены оставаться безграмотными и трудиться на благо господ. К слову о гендерном неравенстве того времени, распространявшимся так же и на поначалу скудное обучение женщин, ближе ко второй половине XIX века (а более глобально – к началу XX века) образование начали получать все больше и больше женщин. Однако значение женского обучения по-прежнему оставалось второстепенным и направленным скорее на научение тому, как быть «хорошей матерью и супругой», а не на получение знаний и навыков для самореализации и развития в профессиональном сообществе [4].

С развалом Российской Империи и образованием СССР страну потрясли большие перемены, все усилия властей были направлены на конструирование «человека советского» («*homo sovieticus*»). Наиболее известными лоббистами в сфере образования являлись Н.К. Крупская и А.В. Луначарский, благодаря их деятельности институт образования претерпел колоссальную трансформацию и стал тем необходимым фундаментом, соответствующим целям по воспитанию советского гражданина [41, 22]. Имеет место процесс демократизации образования [20]. Для преодоления проблемы нехватки квалифицированных сотрудников в различных регионах, университетская система работает по принципу распределения, в соответствии с которым после получения образования человек был обязан отработать некоторое число лет на определенном рабочем месте в городе по распределению [36].

С формированием Российской Федерации произошла модернизация законодательства и сферы образования как таковой. Разрыв тоталитарного способа государственного устройства способствовал еще большей демократизации образования, что привело к более свободному проектированию карьерных траекторий среди выпускников школ. Разнообразие университетов и предлагаемых образовательных программ позволяет выстроить персонифицированный трек развития своих профессиональных навыков и компетенций. Изменения затронули и саму процедуру приема в университеты с постепенным введением Единого Государственного Экзамена (ЕГЭ) в 2001 году. Введение ЕГЭ способствовало некоторой стандартизации процедуры проверки усвоенных школьниками знаний, что позволило значительно оптимизировать процесс поступления, вытеснив сдачу индивидуальных экзаменов, отличающихся между различными университетами [35]. Таким образом, можно отметить, насколько изменялась доступность образования в России на протяжении последних столетий.

Согласно выводам, изложенным в аналитическом докладе НИУ ВШЭ, посвященному дифференциации доступности высшего образования в России [23], в настоящее время

основными барьерами доступности высшего образования можно обозначить территориальный признак, стоимость обучения, высокую конкуренцию, недостаток информации, разрыв образовательного уровня в регионах. Эти проблемы активно репрезентируются в СМИ, призывая к общественному обсуждению и разработке решений, направленных на ослабление и устранение этих барьеров. Освещение обозначенных барьеров в публичном пространстве способствует формированию общественного впечатления о доступности высшего образования в целом.

Считается, что лучшие университеты России располагаются в ее европейской части – в Санкт-Петербурге и Москве, например, в уже упомянутом ранее рейтинге лучших вузов России RAEX-100 за 2025 год [1] на первых 10 позициях располагаются восемь вузов Москвы, один вуз Санкт-Петербурга и один вуз Екатеринбурга. Из-за географического положения абитуриенты из отдаленных регионов сталкивались со сложностями в процессе поступления в вузы центрального региона: им приходилось планировать специальные поездки для подачи документов в университет, не имея никаких гарантий поступления. В отличие от них, жители столицы подавали документы в своем городе и избегали дополнительных финансовых и временных трат.

С повсеместным распространением пандемии COVID-19, образовательная среда трансформировалась, многие ее аспекты были цифровизированы [13]. Так, поступить в вуз стало возможным посредством подачи документов через Интернет, что исключает личное присутствие абитуриента в другом городе. Это способствовало большей доступности возможности получить высшее образование в одном из топовых вузов, при этом не тратя деньги и время на поездку для подачи документов. Абитуриенты из регионов получили больше возможностей для выбора своего образовательного маршрута, в то время как для жителей Москвы и Санкт-Петербурга это нововведение означало увеличение конкуренции за места в конкурсных списках. Также свое развитие получил феномен онлайн-образования, который реализуется благодаря информационным технологиям и сервисам дистанционного взаимодействия между обучающимися и преподавателями. Таким образом, можно получать образование, например, московского кампуса Высшей школы Экономики, физически находясь в северном регионе или вообще в другой стране и имея лишь доступ в Интернет и компьютер.

Вопреки общественному мнению, образовательные услуги не являются бесплатными по своей сути, поскольку фактически процесс оказания услуги данного вида оплачивается либо государством за счет средств федерального или регионального бюджета, либо физическим или

юридическим лицом с привлечением собственного капитала. Примечательно, что в 2022 году из содержания закона РФ об образовании была исключена формулировка «государственная и муниципальная услуга в сфере образования» [39]. Этой инициативой законодатели выразили стремление устранить ассоциацию педагогической деятельности с коммерческой услугой, где ее поставщиком выступает образовательная организация, а потребителем – учащийся. Тем не менее, стоимость программ высшего образования является важным фактором его доступности среди граждан: высокая стоимость обучения может препятствовать получению образования среди различных категорий населения [12], включая, например, малоимущих и социально уязвимых семей [28]. На поддержку таких социальных групп направлены различные государственные инициативы.

Программа образовательных кредитов реализуется в России с 2000 года, претерпев несколько пересмотров концепции на протяжении 20 лет, в 2020 году правительству удалось снизить ставку за кредитование до «3% годовых и увеличить срок его погашения до 15 лет, что привело к резкому росту числа обратившихся за таким кредитом» [2]. Выделяют также и альтернативные способы поддержки финансовых затрат на образование: выделение различных грантов и стипендий, оплата обучения средствами работодателей («целевое обучение»), принадлежность к льготным категориям (дети-инвалиды, инвалиды I/II групп, дети-сироты, ветераны боевых действий, участники СВО и их дети, а также другие жители), подразумевающая приоритетное зачисление в вуз или обучение за счет средств бюджета.

В последние годы в России медийная активность вузов вышла на новый уровень, что предоставляет возможность для использования этой деятельности в качестве индикатора открытости и доступности вузов со стороны абитуриентов и населения. Так, в исследовании медиаактивности вузов, проведенным Brand Analytics, в тройку лидеров-регионов вошли Москва, Санкт-Петербург и Пермский край [24]. Коммуникация образовательного учреждения в социальных сетях и СМИ формирует не только имидж вуза, но и интерес и доступность среди выпускников школ.

По результатам мониторинга [8], проведенного аналитическим центром ВЦИОМ в 2024 году, 38% россиян считают, что доступность высшего образования выросла в сравнении с советским периодом, однако большинство (51% респондентов) по-прежнему убеждено в том, что относительного советского времени доступность образовательных возможностей снизилась.

На примере обозначенных выше барьеров доступности высшего образования можно заметить, что публикация материалов о трудностях поступления и высокой стоимости

образования – сама их репрезентация в СМИ –, во-первых, способствует информированию населения о проводящихся законодательных инициативах, касающихся сферы образования, во-вторых, склоняет к формированию образа высшего образования как труднодоступного блага, даже с учетом наличия мер государственной поддержки обучения. Освещение этих барьеров реализуется с помощью экспертных комментариев, статистических данных, персональных историй поступления и научных исследований. Следовательно, амбивалентность образа системы высшего образования особенно явно очерчивается при заявлениях об успехах в образовательной сфере, в то же время отсылающих к трудностям, которые система постоянно претерпевает и воспроизводит.

1.2.3. Престижность высшего образования в общественном восприятии

Понятие престижа является одним из основополагающих в теории социальной стратификации Макса Вебера, наряду с богатством и властью. Под престижем понимается некоторое уважение и общественное признание, которое социум обращает в сторону индивида в соответствии с занимаемым им местом в социальной иерархии, обладаемым влиянием, а также имеющимися знаниями, навыками и материальными ресурсами. Престиж в целом может атрибутироваться к различным сферам «обладания»: владение недвижимостью, принадлежность к определенному социальному классу, наличие уникальных профессиональных навыков и образования, а также прочих исключительных элементов и видов деятельности [31]. Престиж связывается с различного рода классовыми привилегиями, например, в контексте высшего образования: обладание дипломом престижного университета дарит его обладателю некоторый социальный капитал (помимо знаний и навыков), помогающий в продвижении по карьерной лестнице [25].

Рассматривая высшее образование через призму концепции символического капитала Пьера Бурдьё, стоит отметить роль этого института в воспроизводстве иерархичности в обществе, а также в формировании статуса самого индивида. Символический капитал выражается в обладании некоторой репутацией или авторитетом, который легализуется в группе индивидов, обладающих равным уровнем такого капитала, или на более широком уровне – полномочными инстанциями. Ключевой элемент символического капитала в образовательной среде – диплом, являющийся социальным маркером, поскольку дает преимущества в виде более легкого трудоустройства, повышенной стартовой зарплаты, доступа к сообществу профессионалов.

Престиж высшего образования сопрягается с престижем самого учебного заведения, хотя

и является по сути субъективной оценкой, отражающей то, насколько значимую позицию занимает вуз в системе высшего образования. Эта оценка формируется посредством того, что в обществе – среди работодателей, выпускников, абитуриентов и их родителей – создается некоторое представление о качестве образования, оцениваемом через навыки и знания, которые применяют выпускники вуза на рынке труда. В исследовании, посвященном формированию образовательных траекторий выпускников школ, поднимается тема важности престижности учебного заведения для абитуриентов как отражения «качества получаемого образования, его актуальности и вариативности» [25]. Ведущие институты описываются словами «престижный», «ведущий», «лучший», «крупнейший», «эталон», «первоклассный», «титулованный», «известный», а престижные при этом – словосочетаниями «качественное образование», «упор на», «должное образование» [25].

Помимо субъективного аспекта есть и более объективный способ оценить престижность вуза – его статусность; она формируется через специализированные рейтинги, которые оценивают образование по различным параметрам. Например, к таким можно отнести: академические показатели, научные показатели, уровень трудоустройства среди выпускников. Следовательно, рейтинги вузов, существующая репутация и путь развития формируют символический капитал, который в свою очередь перераспределяется между выпускниками заведения. Последние же замыкают символический цикл, становясь воспроизводителями и усилителями этого символического капитала – достижения выпускников повышают репутацию вуза в глазах общественности. Одновременно с воспроизведением символического капитала происходит и воспроизведение социального неравенства посредством «легитимации социального порядка» [33]: выпускники из семей, обладающих высоким экономическим и культурным капиталом, чаще также поступают в престижные университеты, воспроизводя неравенство в доступе к качественному и престижному образованию из поколения в поколение [33].

Как было отмечено ранее, столичные вузы считаются более престижными благодаря комплексному сочетанию социокультурных, экономических и карьерных преимуществ. Они занимают высокие позиции в рейтингах России, предлагают широкий диапазон программ высшего образования, используют современное оборудование и информационные технологии, а также привлекают высококвалифицированных преподавателей. Также, благодаря географически выгодному расположению по соседству с крупными технологичными компаниями, вузам удается организовывать тесное сотрудничество, полезное как студентам, так и компаниям,

например, посредством организации обязательной практической подготовки или партнерстве и спонсировании образовательных программ.

В медиапространстве престиж высшего образования формируется за счет медийной активности самого вуза, тональности публикаций о вузе в сообществах общей направленности и обсуждения результатов расчетов рейтингов. Стабильный позитивный образ научного лидерства, успех образовательных результатов, поток престижных сотрудничеств с известными компаниями – все это способствует формированию и укреплению репутационных позиций вуза, сообщая обществу о качестве институционального образования. Медийная видимость и разнообразия контента позволяет охватывать различную аудиторию, что способствует повышению престижности учебного заведения и привлечению большего числа абитуриентов и работодателей. Таким образом, происходит усиление символического капитала вуза, придавая большую ценность статусу выпускника конкретной образовательной организации.

В контексте российского высшего образования особое значение имеет феномен москвоцентричности образовательного пространства. Москва выступает как символический центр производства образовательного престижа, именно с московскими вузами чаще связываются представления о качестве образования, широких карьерных возможностях, международных связях. В данном смысле престиж высшего образования оказывается неравномерно распределенным в пространстве, концентрируясь вокруг столичных университетов, что только воспроизводит разрыв между периферией и центром. Москвоцентричность фигурирует и в проблеме социальной доступности образования, связанной с высокими академическими требованиями, различиями в информационной и культурной подготовке, стоимостью жизни в городе, сложностями переезда.

Москва в исследовании рассматривается не только как географическая рамка, но и как некоторая символическая позиция в системе высшего образования в РФ. Она усиливает престиж образовательного пути, но при этом придает вопросу доступности более социально чувствительную модальность.

1.2.4. Нарративы в медиа и конструирование социальной реальности

В эпоху повсеместной цифровизации средства массовой коммуникации играют ключевую роль в моделировании способов и паттернов восприятия окружающего мира. Новости, статьи в медиа, рекламные посты и видеоролики, публикации в социальных сетях, все это – единицы сообщений, ежедневно генерируемые и проходящие через человеческое восприятие. Транслируемая информация трансформируется в устойчивые представления об

объективной реальности – нарративы, формирующие в свою очередь истории, способы интерпретации различных феноменов, обретающие собственный смысл и причинно-следственные связи. Нарративы являются не столько отражением [27] социальной действительности, сколько социальной структурой, конструирующей реальность; они формируют общественные представления, упорядочивают коллективный и индивидуальный опыт, а также воздействуют на идентичность.

Среди механизмов влияния нарративов на человеческое сознание можно выделить следующие [21]: выбор того, какие событие и феномены освещаются, а какие – нет; использование эмоционально окрашенных образов и лексических оборотов, провоцирующих на возникновение определенных чувств; режиссирование того, через какую акцентуальную призму воспринимается феномен – фрейминг; итеративность возникновения схожих сюжетов для их закрепления в общественном поле; комментарии экспертов, призванные для подтверждения установленной интерпретации события.

Стоит упомянуть о существовании так называемого эффекта «информационного кокона», когда индивид направляет свое внимание на потребление исключительных каналов-трансляторов медиаконтента, являющихся для него конформными и не создающими диссонанс со сформировавшимся мировоззрением [16]. Это мировоззрение, в свою очередь, может быть довольно мейнстримным, то есть навязанным средствами массовой информации и затем интернализированным индивидом вместо собственного «независимого» представления о социальной реальности» [16]. Таким образом, долгосрочное транслирование в СМИ определенных нарративов способствует, в соответствии с теорией культивации Джорджа Гербнера, формированию устойчивых представлений о мире, феномены в котором являются типичными и распространенными [17]. Благодаря медиатизации нарративы трансформируются из *«историй о реальности»* в саму *«реальность»*. Медиатизацию принято рассматривать «как двунаправленный процесс: влияние медиа на социальную ткань жизни и изменения самих медиа» [42]; как процесс, продолжающийся в нелинейной форме. Иначе говоря, социальные феномены из СМИ влияют на поведение индивидов, становясь частью реальности: публикация рейтинговых позиций университетов помогает абитуриенту выбрать вуз для поступления, а истории успешных выпускников вуза изменяют представление о престижных направлениях подготовки.

Новостные сообщества в социальных сетях охватывают широкую аудиторию, поскольку распространяют информацию об актуальных событиях из социальной реальности. К одной из

таких категорий информации относятся вопросы, связанные с системой высшего образования: рейтинги вузов, ход приемной кампании, реформы высшего образования, события из жизни студентов, научные успехи университетов и прочее.

Особенностями публикации подобных сообщений в Интернете можно обозначить охват широкой аудитории, оперативность и частоту публикации контента, стандартизированную форму текстов и эмоциональный акцент на деталях контента. Образ высшего образования складывается в том числе и через новостные сообщества в социальных сетях, он формируется по малейшим частям – из коротких новостных заметок, обсуждений пользователей, шуток и реакций. Следует добавить, что из-за того, что публикации об университетах могут отражать не только позицию официальных представителей образовательного пространства, но и опыт студентов и родителей, образ высшего образования становится менее управляемым извне, но при этом – более многогранным и приближенным к реальному опыту участников образовательного процесса.

Резюмируя, через новостные сообщества формируется некоторый образ высшего образования, включающий в себя: имидж как всей образовательной среды, так и отдельных университетов; стереотипы, например, об уровне дохода выпускников технических и гуманитарных специальностей; ожидания об обучении, часто идеализированные и местами расходящиеся с реальностью; существующие проблемы и призывы к их решению за счет общественной огласки.

1.3. Методологические подходы к работе с текстовой информацией

1.3.1. Специфика предобработки текстов из социальных сетей

Ключевая особенность социальных сетей заключается в создании особого пространства для объединения людей, обсуждения мнений и общения. Тексты социальных сетей представляют собой специфический тип эмпирических данных, они одновременно фиксируют коммуникацию и реакции пользователей и цифровые следы их взаимодействия с институтами. Реальные публикации, сообщения, комментарии – могут являться «грязными» данными, в отличие от текстов публицистической и академической стилистики. Пользователи используют упрощенный способ коммуникации с другими, поскольку основной задачей быстрого общения является передача идеи, а не ее грамотное оформление. Пользовательские сообщения часто характеризуются ошибками и опечатками, неполнотой лексики, сокращениями и сленговыми выражениями, использованием эмодзи и смайликов, обценной лексики, различных символов, например, хештегов, ссылок – такие данные относятся к типу user-generated-content (данные,

сгенерированные пользователем) [47]. Рассматриваемые в данной работе типы текстов важно различать: публикации официальных сообществ университетов и комментарии пользователей. Комментарии можно отнести к UGC, поскольку они фиксируют спонтанные реакции, оценочные суждения и уточнения, иронию. Публикации же ближе к институциональному жанру медиатекста, часто сохраняют признаки имиджевого или новостного жанра, являются сообщениями в публичной коммуникации. Поскольку в корпусе представлены различные сообщества, мы встретим в них несколько разных типов текстовых данных, преобладать будет институциональный медиатекст, имеющий все признаки новостного жанра, однако среди них могут найтись и тексты с гибридными чертами (как институциональными, так и UGC), имеющими, например, авторские комментарии.

Такой текст необходимо подвергать предварительной обработке: приведение слов к начальной форме (лемматизация, стемминг), токенизация (разбиение текста на токены-слова), а также удаление стоп-слов и специальных символов, которые могут «зашумлять» данные и снижать точность работы моделей. Нормализация слов необходима, поскольку русский язык имеет довольно разнообразные правила словообразования и склонения, а лемматизация позволяет учесть часть речи, а также сохранить семантику и уменьшить размер словаря (как и приведение к нижнему регистру). Лемматизация в таком случае является более полезным инструментом, чем стемминг, который более применим в других языковых семьях из-за специфики обрезания окончаний. Таким образом, подготовка текста помогает придать данным структурированный вид – последовательность, состоящую из токенов –, который позволяет использовать инструменты векторизации (TF-IDF, Bag-of-Words, Word2Vec, BERT), кластеризация, классификации и прочее.

Однако чрезмерная очистка текста может нести методологические риски, эмодзи, восклицания, хештеги могут выступать в качестве индикаторов в зависимости от задачи. Поэтому важно при осуществлении манипуляций над текстом сохранять при этом его оригинальную версию. В прикладных исследованиях русскоязычных социальных медиа встречается использование подобной логики. Например, в недавней работе Д. Тимошкина и др., посвященной цифровым следам структурной интеграции мигрантов во «ВКонтакте» [37] для линейного классификатора применялись исправление ошибок с помощью контекстной автокоррекционной модели JamSpell, лемматизация при помощи пакета Natasha, а также замена именованных сущностей, удаление стоп-слов, пунктуации, частотных и редких слов, векторизация текстов через TF-IDF. При этом предварительная очистка не применялась для

нейросетевой модели, потому что такое вмешательство в структуру текста могло разрушить важную информацию о контексте и формах слов, что существенно для моделей чувствительных к семантике. В этой работе сравнивались линейная модель, собственная нейросетевая архитектура и fine-tuning RuBERT-tiny (показала лучшие результаты).

1.3.2. Поиск смыслов: векторизация и вычислительная семантика

Векторизация позволяет произвести перевод смыслов с «человеческого» (естественного) языка на более понятный машинам язык – язык числовых представлений. Важно принять во внимание, что применимость разных методов отражается в том, какие отношения смыслов удастся обнаружить алгоритму. Базовым подходом к векторизации является Bag-of-Words («мешок слов»), этот метод позволяет представить каждый текст в виде вектора размерности числа формирующих корпус слов. По сути, происходит примитивный подсчет частот без учета порядка слов, который можно несколько улучшить, применив статистическую меру TF-IDF (Term Frequency – Inverse Document Frequency). TF-IDF уравнивает значимость слов в конкретном тексте-документе и его редкость встречаемости во всем корпусе с помощью логарифмического сглаживания. Использование данных инструментов позволяет быстро и без больших затрат ресурсов разработать базовое решение разведывательного поиска смыслов. Однако, важным ограничением метода является неспособность в определении семантической близости токенов и различении омонимов в зависимости от контекста, что представляется ключевым в анализе нарративов.

Дальнейшее развитие связано с дистрибутивной семантикой. Дистрибутивная гипотеза сообщает о том, что смысл слова можно определить по контексту, в котором оно употреблено. Эта идея находит свое отражение в семействе моделей Word2Vec, модель позволяет предсказать слово по окружающему контексту (модель CBOW, continuous BOW), либо наоборот, контекст по слову (модель Skip-gram) [51]. Skip-gram используется чаще с улучшением Negative Sampling, целью ее обучения является максимизация вероятности реальных слов контекста при минимизации вероятности случайных слов контекста, результатов обучения является скрытый вектор «эмбединг». Данный метод ограничен статической природой создаваемых векторов, где одной лексеме соответствует единственный вектор, что может вносить шум в модель, который будет непросто обнаружить. FastText частично решает проблему редких слов и опечаток за счет представления слова через символьные n-граммы.

Контекстуальные модели, прежде всего BERT и его адаптации на русском языке (например, RuBERT [49]), позволяют подойти к решению этой проблемы. Формируются

контекстуальные эмбединги токенов, учитывая контекстные слова по обе стороны от токена, что позволяет повышать качество решаемых задач [46]. Однако, дообучение модели требует значительных ресурсов памяти из-за большого числа параметров, а фиксированная длина входящей последовательности токенов вынуждает сокращать длинные тексты.

1.3.3. Инструменты обнаружения нарративов: от чисел к темам

В работе с цифровой информацией большого объема неизбежно обращение к методам автоматического моделирования. Метод, позволяющий производить автоматическое выявление скрытых тем – тематическое моделирование. Латентное размещение Дирихле (LDA) представляет генеративную байесовскую модель, в ее основе лежит предположение о том, что каждая скрытая тема имеет вероятностное распределение по словарям словаря, которые на более высоком уровне из тем формируют конкретный документ (публикацию) [45]. Смысл метода состоит в воспроизведении апостериорного распределения тем в публикациях и слов в темах по наблюдаемым словам. Применение LDA позволяет обзорно взглянуть на публикаций, объединенные по категориям смыслов, что представляется полезным разведочным инструментом. Однако данный инструмент обладает существенным ограничением, выражающимся в его стохастической природе – неустойчивости результатов. Также тема не равна нарративу, который предполагает не только наличие набора слов, но и сюжетную организацию.

Это различие подтверждается обзорной работой И. А. Рыбаченко [32], в которой автоматизированное извлечение нарратива из соцмедиа описывается с использованием нескольких подходов: мешок слов, онтологии, семантические аннотации, векторные представления, трансформеры и графовые модели. Подчеркивается, что статистические модели типа TF-IDF и Bag-of-Words сохраняют значение для тематической кластеризации, но при этом не способны провести реконструкцию сюжетных связей; подходы с использованием нейросетей хорошо работают с неструктурированными данными, но нуждаются в правилах и проверке; а семантические схемы требуют трудоемкой разметки.

Нарратив, являясь некоторым сюжетным фреймом, состоит из действующих лиц, целей, связей, следствий и причин. В работе с текстовой информацией исследователи часто обращаются к методу контент-анализа, который позволяет выявить существующие закономерности и уникальные паттерны путем изучения содержания корпуса текста. Из паттернов-кодов складываются объединяющие их метанарративы, которые можно обнаружить благодаря лексическим и семантическим маркерам. Нарратив контекстно объединяется набором

слов, выражений и конструкций; составление словаря подобных маркеров может быть полезно для автоматической разметки корпуса текстов, на основе которого затем можно реализовывать решения с использованием алгоритмов машинного обучения.

В близких по логике исследованиях смешанные дизайны уже применяются. Л. А. Видясова и др проводят сопоставление репрезентативного опроса жителей Санкт-Петербурга с цифровыми следами районных сообществ во «ВКонтакте» [5]. Они используют LDA для выделения сфер городской повседневности, а комбинированный алгоритм Word2Vec, BERT & ruGPT-3 для классификации комментариев по пяти категориям эмоций, значение F1-score=0,91. Это довольно важный момент, показывающий, что социальные сети не заменяют опросы или качественный анализ, они позволяют обнаружить коллективные и ситуативные формы реакций.

1.3.4. Поиск мнений и оценка тональности

Подход, именуемый *opinion mining* (анализ мнений), помогает подойти к понятию тональности более вдумчиво. Ключевым преимуществом здесь обозначается не просто поиск позитивного или негативного тона, а поиск того, какое именно мнение выражается в тексте.

Если базовый sentiment-анализ позволяет зафиксировать наличие той или иной эмоциональной окраски в источнике, то анализ мнений предполагает извлечение комплексных оценочных суждений, объединяемых структурой: кто оценивает, какой объект/аспект, какая оценка выражается и какую аргументацию имеет [50]. Аспектно-ориентированный анализ тональности может быть полезен для комментариев. Например, один и тот же комментарий в зависимости от призмы аспекта может оценивать университет позитивно как бренд, но при этом критиковать его инфраструктурные аспекты, поэтому при автоматической разметке целесообразно выделять еще и объект оценки, помимо тона.

Таким образом, оптимальной методологической стратегией исследования может быть определена цепочка последовательных дополняющих друг друга этапов: сбор массива данных публикаций и комментариев, учет текстовой специфики наблюдаемых единиц во время обработки текста под конкретную задачу, построение эмбедингов для поиска семантически близких высказываний, классификация тональности, качественная интерпретация тем как потенциальных нарративов и валидация результатов

1.3.5. Валидация

Поскольку методы автоматического извлечения признаков не устраняют проблемы, связанные с интерпретацией контекста, этап валидации результатов необходим, как отмечают Дж. Гриммер и Б. Стюарт [48]. Для тематического моделирования это может быть осуществлено

с помощью экспертной проверки ключевых слов, а также наиболее репрезентативных документов темы. Для классификации можно использовать ручную разметку части корпуса, разделение данных на обучающую и тестовую выборки, расчет метрик precision, recall, F1-score. Для качественной кодировки должна осуществляться проверка согласованности присваиваемых кодов для обеспечения межкодировочной надежности.

2. Методология исследования. Сбор и предобработка информационной базы исследования

2.1. Методологические основания исследования

2.1.1. Определение ключевых понятий

Под медианарративом в контексте исследования понимается способ смысловой организации и представления информации в текстах публикаций новостных сообществ, формирующий определенные представления о доступности и престижности высшего образования.

Престижность высшего образования рассматривается как социокультурная оценка университета, основанная на упоминании в рейтингах, репутации, успешности карьер выпускников, партнерских соглашений с компаниями.

Социальная доступность высшего образования воплощается в (не)равенстве возможностей получения образования представителям различных социальных слоев, которые определяются некоторыми условиями: географией, финансовым статусом, льготами, формами обучения, наличием бюджетных мест на образовательной программе.

2.1.2. Цель исследования

Выяснить, каким образом через медианарративы в новостных сообществах социальных медиа формируется представление о престижности и социальной доступности высшего образования в Москве в период 2020–2025 гг.

2.1.3. Задачи исследования

1. Провести литературный обзор подходов к изучению проблематики медиадискурса, высшего образования и методов нарративного и тонального анализа текстов.
2. Сформировать корпус эмпирических данных – публикаций новостных сообществ московских вузов во «ВКонтакте» за 2020–2025 гг. и комментариев к ним – и подготовить его к анализу.
3. Операционализировать и выделить в корпусе данных медианарративы престижности и социальной доступности высшего образования через систему текстовых маркеров.
4. Описать тематическую структуру данных и определить, с какими содержательными повестками связаны нарративы престижности и доступности.
5. Проанализировать структуру, динамику, а также показатели вовлеченности публикаций, относящихся к разным нарративным классам.
6. Выявить, каким образом тема социальной доступности проявляется в пространстве комментариев и как характеристики публикаций связаны с содержательным откликом

аудитории.

2.1.4. Основные гипотезы исследования

1. В публикациях новостных сообществ московских вузов во «ВКонтакте» за 2020-2025 гг. нарратив престижности будет представлен чаще, чем нарратив социальной доступности высшего образования.

2. Нарратив престижности будет чаще связан с темами достижений, науки, рейтингов, карьеры, тогда как нарратив социальной доступности – с поступлением, бюджетными местами, стоимостью обучения, общежитием и льготами.

3. В комментариях нарратив социальной доступности будет проявляться в обсуждении барьеров, ограничений и трудностей доступа к высшему образованию, в то время как в публикациях внимание будет уделяться информационному оповещению о событиях, связанных с поступлением.

4. Публикации с нарративом социальной доступности будут чаще вызывать содержательные комментарии, чем публикации с нарративом престижности.

5. Публикации с нарративом престижности будут иметь более выраженную позитивную тональность, чем публикации с нарративом доступности.

6. Содержательный отклик аудитории связан с семантической структурой публикации, с тем, какие темы и смысловые акценты задаются в тексте сообщения.

2.1.5. Теоретический объект исследования

Медиадискурс о высшем образовании в московских университетах в социальных сетях.

2.1.6. Предмет исследования

Смысловые механизмы (нарративы и тональности), через которые в медиадискурсе формируется образ высшего образования в Москве как престижного и/или социально доступного.

2.1.7. Эмпирический объект исследования

Тексты публикаций открытых новостных сообществ социальной сети «ВКонтакте», опубликованные в период с 2020 по 2025 год, а также тексты комментариев пользователей к этим публикациям.

2.1.8. Обоснование выбора платформенного решения как источника данных

В последние годы произошла трансформация предпочтений аудитории, начавшей более активное использование мессенджера Telegram и социальной сети «ВКонтакте» после введения

новых законодательных ограничений весной 2022 года. Форматы использования этих платформ позволяют получать информацию об актуальных событиях страны и региона в кратчайшие сроки, перевешивая многие преимущества, присущие традиционным видам СМИ, радиовещания и телевидения. Вопрос ограниченной доступности информации для пользователей является ключевым в ее потреблении, что способствует перетеканию трафика в альтернативные каналы связи, например, уже упомянутые «ВКонтакте» и Telegram, новый «национальный» мессенджер Мах и другие менее популярные зарубежные мессенджеры. Идея получения данных из Мах сталкивается с рядом трудностей: бойкотирование и сопротивление со стороны населения, не желающего устанавливать данный сервис [11], что снижает общий охват аудитории внутри платформы; сложная процедура регистрации публичного канала, доступная лишь ИП, юрлицам и авторам, имеющим отметку «А+» и регистрацию в реестре РКН, что снижает число каналов распространения информации на платформе; ограниченный функционал API МАХ, ориентированный на управление контентом, а также отсутствие данных за предыдущие периоды, поскольку мессенджер был запущен лишь в марте 2025 года.

По данным сравнительного исследования трафика традиционных СМИ и социальных сетей в июне 2023 года Telegram обошел «ВКонтакте» по аудиторному охвату, далее обходя последнюю всего на 1,4–6,6 п.п.. Однако, в связи с введением ограничений со стороны Роскомнадзора по отношению к мессенджеру Telegram, мы обращаемся к социальной сети «ВКонтакте» в качестве источника данных для проведения исследования, принимая во внимание, что эта платформа является менее популярной, но при этом конкурирующей за охват аудитории наравне с мессенджером и также являющейся лидером по числу публикаций по данным за март 2025 [6]. Наряду с этим важно, что функционал VK API позволяет получить доступ к интересующей нас информации, что является одним из главных критериев в выборе целевой платформы, помимо доступа к данным интересующего периода 2020-2025 гг.

2.1.9. Обоснование выбора временного периода для сбора данных

Определение интервала, за который будет производиться сбор данных, обусловлено рядом событий, которые произошли на уровне всего мира и страны. В первую очередь, пандемия COVID–19 задала мощный импульс цифровизации многих процессов, в том числе и в образовательной среде, что повлекло за собой ее институциональную трансформацию. Онлайн-формат подачи документов для поступления в вуз внес коррективы в привычную модель неравного доступа к престижным учреждениям и ограниченной конкуренции абитуриентов региона. Благодаря дистанционным технологиям, с одной стороны, произошло размывание

географических и финансовых ограничений, препятствующих подаче документов жителями отдаленных регионов, а с другой стороны – это увеличило конкуренцию за бюджетные места. Также, вынужденный дистанционный и гибридный формат реализации образовательных программ с одной стороны позволил продолжать образовательный процесс во время пандемии, но с другой – обострил проблему неравного доступа к технологиям, связи и образованию. Этот период обнажил существующие проблемы, спровоцировал новые и стал стимулом к решению некоторых из них, что видится интересным для рассмотрения через призму репрезентации этих процессов в социальных медиа.

Помимо глобальной пандемии, на уровне России также происходили некоторые изменения, затрагивающие образовательную среду. Так, отказ от Болонской системы в пользу новой трехуровневой модели высшего образования с 2026 года и ее пилотная реализация с 2023 года вызвали неоднозначное обсуждение [3]. Растущие меры поддержки участников СВО и членов их семей также распространились и на сферу образования: этой категории граждан предоставляется большой спектр различных льгот. Например, их включение в категории квот и выделение 10% бюджетных мест в вузах, зачисление граждан в вузы без экзаменов при соблюдении некоторых условий, получение дополнительных баллов в качестве индивидуальных достижений, приоритетное право перевода с платного на бюджетное место – все это вносит коррективы в сложившуюся практику и влияет на восприятие образования как доступного и престижного. Льготы воспринимаются как мера поддержки, однако существует мнение, что студенты, поступившие по квоте, могут испытывать некоторые академические сложности с освоением программы, «занимать чужие места», что переплетается с восприятием социальной несправедливости, создающей неравные условия для абитуриентов, не являющихся льготниками [19]. Таким образом, для одной категории населения введенные льготы повысили доступность образования, в то время как для других – понизили, это вызвало дискуссии о представлении интересов разных групп выпускников в процессе поступления. В дополнение, престижность некоторых учебных заведений могла несколько девальвировать из-за переживаний о снижении академических успехов и изменения в контингенте обучающихся.

Исходя из этого, мы остановились на публикациях, выложенных в период с 2020 по 2025 годы. Базу данных исследования составляют текстовые посты открытых новостных сообществ социальной сети «ВКонтакте» за 2020–2025 годы.

2.1.10. Логика отбора популярных сообществ для анализа

Поскольку исследование фокусируется на высшем образовании вузов г. Москвы, наше

внимание было обращено напрямую на новостные сообщества, представляющие интересы непосредственно московских университетов. Официальные сообщества в соцсетях есть у многих российских вузов, они используются для распространения новостей о жизни университета, о важных изменениях и событиях. Для того, чтобы алгоритм мог обратиться с помощью API к данным сообщества, группа должна иметь статус открытой для всех пользователей.

Список новостных сообществ был сформирован на основании рейтинга вузов, составленного в рамках проекта «Социального навигатора» медиагрупп «Россия сегодня» и Brand Analytics [30]. В качестве опорного был взят рейтинг за 2025 год, также был выставлен фильтр по университетам г. Москвы. Интегральный рейтинг эффективности коммуникаций объединяет в себе оценку по трем рейтингам – «Информационная открытость», «Присутствие в научно-популярных СМИ» и «Авторитетность» –, отражая ее в виде суммарного индекса. Университеты отбирались по соответствию значения суммарного индекса большему, чем 1, таких в списке оказалось 90. Удобство использования данного рейтинга, помимо многомерности измерений коммуникационной активности, заключается в наличии ссылок, ведущих на страницу сообщества университета в социальной сети «ВКонтакте», что исключило необходимость ручного поиска представительств вузов в списке сообществ

В выборку вошли 90 сообществ университетов г. Москвы (полный список см. В Приложении Б). Парсинг источников данных

2.1.11. Получение ключей доступа

Поскольку эмпирическим объектом данного исследования являются публикации в новостных сообществах социальной сети «ВКонтакте», для формирования эмпирической базы нам необходимо обратиться к методу парсинга данных. Использование VK API позволяет получить доступ к «набору готовых классов, функций или структур для работы с имеющимися данными» [26].

Для предоставления доступа к протоколу API требуется создание сервиса – встраиваемого мини-приложения или игры, либо внешнего standalone-приложения. В данном исследовании реализуется регистрация мини-приложения через личный профиль социальной сети для получения данных ключей доступа, поскольку этот способ исключает излишнюю процедуру авторизации в сервисе VK ID, в который можно перейти только после создания профиля бизнеса и авторизации в сервисе VK Бизнес ID. Само приложение по сути является скрытым, так как недоступно из каталога приложений, то есть функционирующим

исключительно в режиме разработки, что позволяет быстро и без осуществления дополнительных процедур получить доступ к работе с VK API. Таким образом, после создания мини-приложения происходит генерация набора из двух ключей доступа: сервисного ключа, используемого на пользовательской стороне, и защищенного ключа, необходимого для выполнения запросов VK API (см. Рисунок 1).




Рисунок 1 — Интерфейс кабинета работы над мини-приложением для получения ключей доступа

Помимо токена (защищенного ключа) необходимо получить уникальный идентификатор новостного сообщества. Однако, в настоящее время большинство сообществ заменяют числовой идентификатор на короткое имя – никнейм, что несколько усложняет получение оригинального ID, присваивающегося при регистрации группы. Известно несколько способов извлечения данной информации, наиболее популярные из них – это использование сторонних сервисов, например <https://regvk.com/id/> [38], и поиск ID внутри ссылки на любой медиаконтент группы (видео, фото, клип, пост), например в ссылке https://vk.com/msu_official?w=wall-78019879_35781 идентификатором сообщества является часть «-78019879».

2.1.12. Алгоритм парсинга публикаций сообществ

Процесс сбора данных реализован на языке Python с помощью модуля `vk_api`. Была написана функция `get_posts` для извлечения публикаций, она получает тексты постов и пользовательские реакции (лайки, просмотры, репосты, число комментариев) из сообществ социальной сети «ВКонтакте». Поскольку период сбора данных задает рамку загрузки публикаций, функция работает до тех пор, пока не наступит одно из событий: либо закончатся посты, либо будет достигнута публикация от 01.01.2020, являющаяся началом интересующего

временного интервала. Функция принимает на вход следующие параметры: ключ доступа к API, идентификатор сообщества, число выгружаемых постов за 1 итерацию, а также начальную позицию отсчета постов со смещением. Реализация функции основана на методах основного класса `VkApi`, включает инициализацию сессии, создание словаря, смещения, даты останова и флага ее достижения; цикл, в котором происходит отправка запроса к стене сообщества, а для каждого поста в запросе происходит извлечение его даты для проверки вхождения в интервал 2020-2025 годов и извлечение метаданных публикации; также предусмотрена задержка выполнения программы на 0,1 секунды для избежания превышения установленных лимитов запросов (gps). Таким образом, на выходе получаем список из словарей, в каждом из которых содержится информация о публикации. Далее он преобразуется в `pandas DataFrame` и сохраняется в формате «.csv».

Работа по сбору данных заняла около 4 часов, включая занятость самого алгоритма, отладку возникающих ошибок, а также ручной подбор значения смещения для каждого сообщества, старт и мониторинг успешности выгрузки публикаций.

Был сформирован набор из 90 файлов формата «.csv», которые затем последовательно прочитывались и присоединялись к списку из датафреймов, параллельно проходя небольшую обработку отдельных полей. После этого список был преобразован в основной датафрейм, однако, из-за ручной настройки значения смещения, были собраны также и некоторые посты за 2026 год, выходящие за рамки верхней границы нашего периода – 31.12.2025, поэтому на следующем шаге они были удалены. Таким образом, был собран датафрейм, содержащий 345006 публикаций с 01.01.2020 по 31.12.2025. Вес файла составил 510,4 МБ.

2.1.13. Алгоритм парсинга комментариев к публикациям сообщества

На прошлом шаге мы записывали метаданные публикаций, включающие в том числе и информацию о числе комментариев к публикации. В первую очередь был сформирован и присоединен к основному массиву данных справочник, содержащий название файлов «.csv» и идентификаторы сообществ, по этим данным были сконструированы ссылки на публикации с использованием идентификаторов публикаций на стене сообществ. Затем была написана функция `get_comments_from_posts` для извлечения комментариев, она получает тексты пользовательского отклика со страницы конкретной публикации. Функция принимает на вход следующие параметры: ключ доступа к API и ссылку на публикацию. Реализация функции основана на методах основного класса `VkApi`, включает инициализацию сессии, создание словаря, числа комментариев к публикации и флага его достижения; цикл, в котором

происходит отправка запроса к публикации сообщества для получения текстов комментариев. Тексты записываются в одну ячейку через « | ».

Массив данных был отфильтрован, чтобы получить информацию только о тех постах, в которых имелся хотя бы один и более комментариев. После чего полученный набор данных был разделен на две части – первые 50 тыс. публикаций и оставшиеся 61 тыс. Публикаций. Это было сделано для ускорения загрузки данных с использованием самостоятельных процессов в отдельных ноутбуках с разными ключами доступа. Данные извлекались с реализацией сохранения прогресса каждые 100 постов, чтобы не потерять собранные данные в случае сбоя в работе алгоритма. Поскольку запросы выполнялись практически непрерывно, а за один запрос возможно получить не более 100 комментариев, прогресс-бар постоянно отображал наличие ошибки «Too many requests! Sleeping 0.5 sec...», связанной с превышением установленных лимитов запросов, что порядком тормозило процесс или было замечено зависание работы алгоритма. В связи с этим было добавлено условие, помечающее неудачные запросы как «нужна проверка», после чего алгоритм переходил к следующему посту, что позволило несколько ускорить процесс за счет автоматизации обработки подобных случаев. Наряду с этим иногда ошибка превышения числа запросов появлялась в выдаче бесконечно, из-за чего приходилось прерывать процесс и продолжать его заново. Сбор данных занял около суток (включая отладку ошибок и сам парсинг), не учитывая параллельные процессы, развернувшиеся в двух ноутбуках; если бы данные собирались одним потоком, их сбор занял бы большее время.

После получения двух массивов, они были объединены в один для проверки 161 случаев, требующих ручной отладки. По проблемным постам алгоритм прошелся еще раз, не удалось извлечь лишь 24 публикации, при проверке ссылок оказалось, что эти публикации недоступны: они были либо удалены, либо скрыты правообладателем – из выборки их удалили. Некоторые комментарии имели не текстовую природу, а были представлены вложением – видео, аудио или фото, такие комментарии извлекались с соответствующей отметкой об отсутствии в них текста, эти посты были удалены из массива.

Таким образом, был собран датафрейм, содержащий 99280 публикаций, содержащих текстовые комментарии. Вес файла составил 218,1 МБ.

Всего ноутбук, посвященный сбору данных занимает 640 КБ

2.2. Разведочный анализ данных

2.2.1. Описание данных

Датасет, содержащий все публикации, имеет размер 345000x8 и включает следующие

признаки, отраженные в Таблице 1.

Таблица 1 – Описание датасета со всеми публикациями

Поле	Тип	Описание
post_id	int64	уникальный идентификатор публикации на стене сообщества
date	object	дата публикации
text	object	текст публикации
likes	int64	число лайков на публикации
comments_count	int64	число комментариев на публикации
reposts	int64	число репостов на публикации
views	int64	число просмотров на публикации
source_nickname	object	название csv-файла, соответствующего источнику данных

Датасет, содержащий публикации с текстами комментариев, имеет размер 99280x11 и включает следующие признаки, отраженные в Таблице 2.

Таблица 2 – Описание датасета со всеми публикациями-1

Поле	Тип	Описание
post_id	int64	уникальный идентификатор публикации на стене сообщества
date	object	дата публикации
text	object	текст публикации
likes	int64	число лайков на публикации
comments_count	int64	число комментариев на публикации
reposts	int64	число репостов на публикации
views	int64	число просмотров на публикации
source_nickname	object	название csv-файла, соответствующего источнику данных
group_id	float64	уникальный идентификатор сообщества
post_link	object	ссылка на публикацию
comments	object	тексты комментариев к публикации, объединённые в одну строку

Из переменной даты публикации в отдельные переменные были извлечены значения месяца и дней недели. Посмотрим на динамику публикаций (см. Рисунок 2).

Наибольшее число публикаций приходится на 2025 год – 72903 поста, при этом максимальное значение постов внутри года концентрируется в апреле с чуть более, чем 7 тыс. Публикаций. Визуально можно отметить циклические периоды подъема и падения публикационной активности каждые полгода.

Далее посмотрим на то, как проявляется пользовательская активность (см. Рисунок 3). Был рассчитан показатель вовлеченности пользователей engagement, являющийся суммой реакций лайков, репостов и комментариев. Можно отметить, что в качестве активности на публикации лайки ставят более охотно, чем делают репосты и оставляют комментарии.



Рисунок 2 — Динамика публикаций в ежемесячном разрезе




Рисунок 3 — Динамика реакций и вовлеченности пользователей в ежемесячном разрезе

Последние – наименее популярный подвид пользовательского вовлечения в контент. Помимо этого наблюдается резкий рост числа просмотров и проявления активности в конце 2021 года.

Публикационная активность сообществ вузов распределена неравномерно в течение года (см. Рисунок 4). Пик приходится на апрель, далее много публикаций выкладывается в октябре,




Рисунок 4 — Сезонность публикационной активности вузов по месяцам года

ноябре и декабре; в январе происходит резкий спад числа публикаций. При этом месяцы с наибольшей публикационной активностью не всегда совпадают с месяцами максимальной вовлеченности пользователей: например, высокие значения медианной вовлеченности в контент наблюдаются в августе и сентябре, вероятно, это указывает на особую значимость периода начала учебного года и завершения приемной кампании.

Если рассматривать вовлеченность в недельном срезе (см. Рисунок 5), можно отметить цикличность, связанную с графиком рабочих дней – в будние дни активность равномерна, немного возрастает в пятницу и резко идет на спад в выходные. Такая же динамика характерна и для публикационной активности самих сообществ.

На данном этапе важно закрепить некоторые понятия:

- Публикационная активность – динамика публикации контента в сообществе вуза.
- Вовлеченность – пользовательские реакции на публикуемый вузами контент.

Эти понятия следует различать по следующей причине: сообщество может публиковать много контента и получать при этом низкую активность от подписчиков, или наоборот – иметь меньшее число публикаций, но высокую реакцию со стороны пользователей. Среди наиболее активных сообществ можно отметить МИСИС, РАНХиГС, МИРЭА, МГУСиТ и ДипАкадемию. Однако, данные (см. Рисунок 6, Рисунок 7) наглядно демонстрируют тезис о том, то высокая публикационная активность не всегда сопровождается высокой пользовательской вовлеченностью. Так, наиболее заметные показатели вовлеченности у МГАХ, МИРЭА, МГПУ. Это указывает на то, что лидеры вузов по числу публикаций не обязательно являются лидерами по числу реакций, поэтому необходимо разделять понятия интенсивной публикации и реакции




Рисунок 5 – Динамика реакций и вовлеченности пользователей в ежедневном разрезе




Рисунок 6 — Топ-20 вузов по количеству публикаций

аудитории – первая отражает активность сообщества, а вторая – дает характеристику о пользовательском отклике на контент.

Приступим к анализу пользовательских реакций. Природа взаимодействия в социальных сетях такова, что часто распределение пользовательских реакций является сильно скошенным: большинство публикаций получает умеренное число реакций, но небольшое число публикаций может собирать довольно большие значения реакций. В связи с этим стоит обратить внимание на логарифмированное распределение реакций (см. Рисунок 8).




Рисунок 7 — Топ-20 вузов по медианной вовлеченности пользователей




Рисунок 8 — Сравнение логарифмированных распределений пользовательских реакций

Проверка данных на выбросы (см. Рисунок 9) производилась в соответствии с размером межквартильного размаха. Большинство постов получает умеренное число лайков, но есть группа публикаций с довольно высоким пользовательским откликом. Среди комментариев распределение скошено сильнее всего. Серединная публикация набирает мало комментариев, но некоторые отдельные посты собирают очень большие обсуждения. Та же картина наблюдается и с неравномерным распределением репостов. Среди просмотров замечен более длинный хвост

справа – некоторые посты охватили аудиторию большую, чем типичный уровень внимания к подобному контенту.




Рисунок 9 — Сравнение лог-распределений пользовательских реакций

Таким образом, мы подтвердили, что реакции пользователей распределяются неравномерно среди публикаций: небольшая часть контента получает очень высокий отклик, в то время как основная масса публикаций – сравнительно умеренные значения отклика.

Далее проведем анализ текстов публикаций. Обратим внимание на распределения длины текстов публикаций и числа слов в них (см. Рисунок 10). Можно заметить, что в среднем пост




Рисунок 10 — Распределение длины текстов публикаций и числа слов в них (в лог-шкале)

содержит 802 символа или 103 слова, медиана же – 637 символов или 82 слова. Эти показатели говорят о скошенном вправо распределении: большая часть текстов в публикациях имеет умеренную длину, но есть небольшая доля публикаций с очень длинными текстами. Также в выборке присутствуют публикации с одним символом, вероятно, это эмодзи, который выражается иначе, чем текст.

Посмотрим, какая связь существует между переменными (см. Рисунок 11). Матрица ранговой корреляций Спирмена, используемая из-за скошенных распределений, позволяет сказать, что массовые обсуждения часто состоят из более коротких комментариев, а менее массовые – могут содержать более развернутые комментарии, поскольку присутствуют следующие корреляции:




Рисунок 11 — Корреляционная матрица (Спирмен) между метриками пользовательской вовлеченности

- Число комментариев и лайков коррелируют положительно с силой 0,44
- Число комментариев и просмотров коррелируют положительно с силой 0,34
- Число комментариев и репостов коррелируют положительно с силой 0,26
- Число просмотров и вовлеченность коррелируют с силой 0,74.

На графике связи числа комментариев и лайков (см. Рисунок 12) основная масса точек располагается в зоне сравнительно небольшого и среднего числа комментариев и лайков. При этом разброс остается по-прежнему большим: при одном количестве комментариев, число лайков может варьироваться.




Рисунок 12 — Связь числа комментариев и лайков

2.2.2. Предобработка данных публикаций

Посмотрев на имеющийся набор данных в общем ключе, теперь приступим к обработке текстов публикаций и комментариев. Цель предобработки состоит в приведении довольно разнородных «грязных» данных к сопоставимому виду и сформировать новые признаки, пригодные для анализа.

Сначала загружается массив данных с текстами публикаций, пользовательскими реакциями (лайки, репосты, число комментариев, просмотры) и метаданными, затем создаются дополнительные календарные признаки, описанные в разделе разведочного анализа данных. Для признаков пользовательских реакций рассчитываются нормированные на 1000 просмотров показатели, а также логарифмированные значения реакций.

Тексты публикаций подвергаются процедуре нормализации, в ходе которой тексты приводятся к нижнему регистру, из них удаляются лишние символы, эмодзи, ссылки. Это способствует уменьшению технического шума в корпусе, который связан со спецификой публикаций в социальных сетях. После нормализации тексты претерпевают процедуру токенизации. В качестве токенов происходит сохранение слов длиной от трех символов. Из токенов удаляются стандартные для русского языка стоп-слова, а также кастомные слова, включающие частотные служебные слова, названия вузов, технические элементы ссылок и прочее.

Далее происходит расчет текстовых признаков: длины исходного и очищенного текста, число содержательных токенов, количество эмодзи, наличие ссылки, доля заглавных букв, количество вопросительных и восклицательных знаков – все для описания формата публикации и как признаки, потенциально связанные с пользовательским откликом.

Для более точного определения нарративов в тексте была проведена их операционализация. Нарратив престижности операционализируется через маркеры элитности, достижений, рейтингов, научных прорывов, международных связей, экспертности и карьерного капитала. Нарратив доступности включает финансовые, процедурные, информационные и инфраструктурные маркеры: поступление, бюджетные места, общежития, стоимость обучения, квоты, стипендии, льготы, консультации, поддержка и инфраструктура. Для нарративов были составлены регулярные выражения, которые позволяют перевести их присутствие в тексте в измеримые признаки; также это позволяет масштабировать анализ на большой корпус публикаций. Для каждого текста происходит расчет числа маркеров нарративов, а также их плотность относительно длины текста; на основе наличия маркеров публикация относится к одному из четырех классов: «Престижность», «Доступность», «Смешанный: престижность и доступность» и «Другое».

2.2.3. Предобработка данных комментариев и их анализ

Обработка комментариев происходит отдельно, поскольку они рассматриваются в качестве части слоя пользовательской вовлеченности в контент. Строка с объединенными текстами комментариев к публикации разбивается на отдельные реакции, которые подвергаются нормализации, токенизации и очистке от шума и стоп-слов. Число самостоятельных комментариев составило 730210 единиц, они привязаны к публикации, источнику, нарративному классу поста. После чего происходит расчет признаков комментариев в разрезе каждой публикации: средняя длина комментариев, доля вопросительных, содержательных, коротких, дублирующих комментариев, их тональность и число упоминаний барьеров доступности образования. Стоит разъяснить логику, стоящую за различением видов комментариев. Ритуальные комментарии – короткие, стандартные реплики, не несущие самостоятельного содержания, они выражают благодарность, поддержку, эмоцию или формальное вовлечение, при этом не разворачивая обсуждение (например, «класс!», «поздравляю!», «спасибо», эмодзи и прочее). Механические комментарии – выглядят как шаблонная техническая активность, часто эти реплики являются ответом на призыв к действию в тексте поста (например, «готово», «+», «ок», «да»). Подвид механических комментариев – конкурсные комментарии – они появляются под постами с розыгрышами, конкурсами и постами, где пользователей специально просят сделать репост, отметить друзей или что-то написать (например, «участвую», «репост сделал», «@‘отметка_друга’»). Наконец, содержательные комментарии – в них пользователь действительно выражает смысловую

реакцию, он может что-то уточнять, задавать вопрос, приводить оценку или участвовать в обсуждении (например, «когда увеличат число бюджетных мест?», «[о дистанционном обучении] будут ли снижать цены на очную форму обучения, учитывая, что она становится заочной?»). Содержательные комментарии определяются соответствием правилам: достаточная длина (> 20 символов), достаточное количество слов (хотя бы 3 токена), комментарий не является ритуальным и дублирующим, или комментарий является вопросом. После этого происходит умножение числа комментариев к посту на долю содержательных комментариев к посту, определяется целевая переменная высокого содержательного отклика в комментариях к публикации. Пост относится к положительному классу, если значение `meaningful_comm_clean` выше 75-го перцентиля (а именно – 3,6). Так мы не просто анализируем средние различия между нарративами, а заодно и проверяем, какие признаки связаны с принадлежностью публикации к группе постов с высоким содержательным откликом в комментариях.

$$\text{meaningful_comm_clean}_i = (1 - \text{contest_flag}_i) \cdot C_i \cdot S_i, . \quad (2)$$

Где C_i – общее число комментариев к публикации i , S_i – доля содержательных комментариев среди комментариев к этой публикации, а `contest_flagi` принимает значение 1 для конкурсных или механических постов и 0 для остальных.

В работе тональность публикаций оценивалась словарно-правильным способом, согласованным с общей логикой `weak labelling`. Для каждого текста рассчитывалось число позитивных и негативных лексических маркеров, найденных с помощью регулярных выражений. К позитивным маркерам относились слова и словоформы, связанные с успехом, достижениями, благодарностью, победами, развитием; к негативным – слова и словоформы, связанные с проблемами, барьерами, трудностями, конфликтами, рисками, несправедливостью. Ознакомиться с правилами можно в Приложении Е. Числовая оценка тональности рассчитывалась по формуле:

$$\text{sentiment_score} = \frac{\text{positive_marker_count} - \text{negative_marker_count}}{\sqrt{\text{token_count}}} \quad (1)$$

Такая нормализация позволяет учитывать длину текста: один и тот же перевес позитивных или негативных маркеров имеет меньшее значение в длинной публикации, чем в короткой. Полученная шкала не является вероятностной и не ограничена строго диапазоном от -1 до 1 – это вещественный показатель, центрированный около нуля. Значения выше нуля интерпретируются как сдвиг в сторону позитивной тональности, значения ниже нуля – как сдвиг в сторону негативной тональности. Для категориальной интерпретации использовались

следующие пороги: Позитивная тональность – $\text{sentiment_score} > 0.18$, нейтральная – значение показателя лежит в промежутке $[-0.08; 0.18]$, негативная – $\text{sentiment_score} < -0.08$. Этот показатель sentiment_mean представляет собой среднее значение рассчитанного признака внутри соответствующего нарративного класса.

В рамках выделения пула содержательных комментариев происходит удаление комментариев, похожих на спам-активность: слишком длинные комментарии, ссылочные реплики, шум на английском языке, комментарии с большим числом повторяющихся токенов. Благодаря этому появляется возможность проводить анализ содержательных типов пользовательских реакций (вопросов, жалоб, уточнений и прочее), а не ограничиваться лишь агрегированным откликом на уровне публикаций. После фильтрации коротких, дублирующих, ритуальных, конкурсных и похожих на спам комментариев, остается 215406 содержательных комментариев (около 29% от всего пула из 730210 комментариев). Среди них доля вопросов составляет 34%, а доля комментариев с маркерами барьеров доступности – 8%. Помимо этого были выделены типы комментариев и рассчитаны их доли: жалобы относительно барьеров доступности (0,6%), общие жалобы или критика (2%), вопросы о доступности (5%), выражение поддержки или благодарности (19%), общие вопросы и уточнения (31%), другие (44%). Среди комментариев с жалобами или критикой были выделены темы, их доля среди такой категории отклика, а также частотный нарратив (для удобства, сократим их до «Д», «П», «С», «Др»), к которому относятся комментарии: стоимость обучения и оплата (34%, П), организационные/технические проблемы (24%, Д), подача документов (8%, Д), результаты экзаменов (3%, С), качество онлайн-обучения (3%, Др), общежития и кампус (1%, Д).

Далее были рассчитаны доли содержательных комментариев с маркерами барьеров доступности в срезе нарративов постов (см. Рисунок 13). Можно заметить, что наибольшие значения долей таких комментариев все соответствуют нарративу доступности, следующие по величине значения относятся к смешанному нарративу и наименьшие доли соответствуют нарративу престижности. Это говорит о том, что в постах, содержащих нарратив доступности (и смешанный нарратив престижности и доступности) концентрируются содержательные комментарии, связанные непосредственно с вопросами доступности и ее барьеров.

Дополнительно были рассмотрены случаи со смещением пользовательского обсуждения, где рамка публикации является имиджевой и престижной, а в комментариях задают практические вопросы доступа. Мы имеем дело не с общей закономерностью, а с иллюстрацией качественных кейсов, поскольку автоматическая разметка не всегда точно отделяет




Рисунок 13 — Матрица соответствия нарративов публикации комментариев с маркерами барьеров доступности

престижность от смешанных публикаций.

В срезе по нарративам в «Доступность» попали 34364 единицы, в «Престижность» – 65103 единицы, в «Смешанный» – 49963 единицы, остальные 65978 комментариев попали в категорию «Другое». Примечательно, что комментарии в нарративе доступности в половине случаев являются вопросительными. Среди всех комментариев были выделены темы по барьерам доступности (прием документов и зачисление, результаты экзаменов, финансовая составляющая обучения, меры поддержки, дистанционное обучение, общежитие и кампус), а также была рассчитана доля содержательных комментариев с такими темами и преимущественный нарратив, в рамках которого они упоминаются. Доли комментариев по барьерам доступности составили от 1 до 4% от числа всех содержательных комментариев: 4% по теме зачисления, 2% по темам финансов, экзаменов, дистанционного обучения, 1% – по темам общежитий и мерам поддержки; тема про меры поддержки относится к смешанному нарративу, остальные – к нарративу доступности.

3. Анализ данных

3.1. Нарративная структура университетской коммуникации

3.1.1. Сравнение нарративных классов

На данном этапе публикации сравниваются по четырем нарративным классам: «Престижность», «Доступность», «Смешанный: престижность и доступность» и «Другое». Сравнение строится по нескольким видам пользовательской реакции – просмотры, лайки, репосты, комментарии, содержательные комментарии, вопросительные комментарии. Благодаря этому удастся проверить, отличаются ли нарративы по характеру пользовательской вовлеченности.

Больше всего постов относится к престижности (112 тыс.), около 100 тыс. – к смешанному типу, 45 тыс. – к доступности и 84 тыс. – к категории «другое». У престижности самые высокие медианные просмотры (3174) и второй по значению лайк-рейт (10,24 лайков на 1000 просмотров)– престижные сюжеты получают хорошую видимость (2761) и позитивную реакцию аудитории (8,31 лайк на 1000 просмотров). Самый высокий лайк-рейт у категории другое (11,59), скорее всего, туда попадают поздравления, культурные посты, студенческая жизнь и эмоциональные публикации. Комментарии не являются популярными относительно лайков, но для социальных сетей это распространено. По содержательным комментариям лидирует доступность. Причем публикации про доступность чаще вызывают вопросительные и содержательные комментарии. Это логично, темы, связанные с поступлением, общежитием, правилами приема и стоимостью обучения, важны для абитуриентов и требуют уточнения. Доступность имеет самый высокий репост-рейт – важной информацией чаще делятся и пересылают другим. Престижные посты больше окрашены позитивно ($\text{sentiment_mean} = 0,22$) – победы, успехи, достижения – а доступность окрашена чуть менее позитивно ($\text{sentiment_mean} = 0,10$). Доступность связана с более «серьезными» темами – документы, условия, барьеры, стоимость. И наконец, среднее число упоминаний маркеров доступности в комментариях – выше среди публикаций о доступности. Больше содержательных комментариев-вопросов, больше вовлеченность. На данном этапе видно, что престиж работает как имиджевая коммуникация, а доступность – как коммуникация, требующая уточнений и обратной связи.

На графике (см. Рисунок 14) с отражением динамики присутствия нарративов в публикациях заметно, что посты с доступностью в течение шести лет имеют тренд на потерю доли в коммуникации университетов. При этом доля престижности, наоборот, в общем тренде возрастает. Примечательно, что в 2022 году у постов с доступностью был момент локального




Рисунок 14 — Динамика классов нарративов в публикациях по годам

максимума, а у престижности – локального минимума. Вероятно, это может быть вызвано уменьшением числа мероприятий, конкурсов, конференций и увеличением публикаций о мерах поддержки, изменениях в правилах приема, связанных с изменением геополитической обстановки на территории России и ближайших государств.

Для того, чтобы сравнить нарративные классы, используется тест Манна-Уитни. Выбор пал именно на него потому что показатели вовлеченности в соцмедиа имеют ненормальное распределение, где большинство постов имеет мало комментариев, а меньшая их часть – очень много откликов. Рассчитывается p -value и rank_biserial (размер эффекта). При большом корпусе даже мелкие различия становятся статистически значимыми, поэтому направление эффекта помогает строить более корректные интерпретации, помимо опоры только на значимость. Из-за большого корпуса почти все сравнения оказываются статистически значимыми. Посты с нарративом престижности имеют более низкие показатели лайков, репостов, содержательных комментариев, чем остальные посты. Такие посты скорее выступают скорее как способ вести имиджевую коммуникацию, чем вовлечь аудиторию. Посты с нарративом доступности получают меньше лайков, но больше репостов и содержательных комментариев. Такие посты работают лучше как способ распространения полезной информации, которую можно обсудить. Посты со смешанным нарративом тоже получают меньше лайков, чуть выше репостов. При этом такие посты не дают прироста в содержательном отклике в комментариях.

3.1.2. Оценка качества автоматической разметки

Для оценки качества автоматической разметки на основе правил (weak labelling) была проведена ручная валидация наборов данных из 600 публикаций и 400 публикаций со слоем комментариев. Выборка данных строилась как диагностическая: в нее вошли наблюдения из разных автоматически выделенных нарративных классов, более сложные пограничные случаи со смешанными или слабо выраженными маркерами, а также публикации с высокой вовлеченностью; выборка с комментариями также была стратифицирована по типам реакции.

Разметка выполнялась по заданным категориям. Для постов фиксировался нарративный класс, подтип престижности или доступности, тональность, релевантность и уверенность разметки. Для комментариев фиксировался тип реакции, наличие вопроса, обсуждения барьеров доступности, тональность, признаки конкурсной или механической активности. Результаты валидации показывают, что автоматическая разметка должна интерпретироваться как weak labelling, то есть как приближенная эвристическая классификация, а не как экспертная разметка корпуса данных. Для нарративов постов совпадение с ручной разметкой оказалось ограниченным, точность составила 0,34, а macro F1 – 0,25. Основное расхождение связано с тем, что автоматические правила часто обнаруживают маркеры престижности или доступности в публикациях, которые при ручной разметке чаще относятся к категории «другое». Для тональности постов результаты лучше, но также неоднозначны – точность составила 0,58, а macro F1 – 0,34. Наиболее сильное расхождение связано с переоценкой позитивных публикаций, относя размеченные вручную нейтральные тексты к позитивным.

Валидация комментариев далее выявила ограничения в автоматической классификации. Для типа реакции точность составила 0,37, а macro F1 – 0,21. Частотные ошибки связаны со смешением содержательных, ритуальных, благодарственных и конкурсных реакций. Это сообщает о том, что пользовательские реакции сложнее формально классифицировать, реакции могут быть близки по внешним признакам, но отличаться по коммуникативной функции. Более того, например, саркастические и ироничные высказывания по правилам кодируются одним способом, а при ручной разметке – другим. Признак вопросов в комментариях показал хороший результат, правила находят все случаи, но при этом иногда срабатывает лишний раз. Признак обсуждения барьеров не поддается корректной интерпретации, поскольку из 400 постов встретился лишь 3 раза.

Таким образом, ручная валидация не опровергает основную логику исследования, а скорее уточняет границы применимости разработанных правил автоматической разметки

данных. Полученные признаки могут быть использованы для анализа больших массивов данных как эвристические индикаторы, позволяющие выявить общие различия между группами комментариев и публикаций. Однако они не должны трактоваться как безошибочная экспертная классификация, поскольку в рамках проведения исследования отсутствовала возможность привлечения разметчиков для обеспечения межкодировочной надежности – проведенная валидация может быть излишне строгой. Дальнейшие выводы исследования интерпретируются как результаты анализа операционализированных, автоматически выделенных нарративных классов и классов комментариев с учетом имеющихся ограничений. Следовательно, автоматические метки нарративов не интерпретируются как надежная индивидуальная классификация каждой отдельной публикации. Конкретный пост, автоматически отнесенный к престижности, доступности, смешанному классу или категории другое, не рассматривается как безошибочно размеченный экспертный объект. В дальнейшем результаты интерпретируются на агрегированном уровне: как частоты, относительные различия между группами и устойчивые ассоциативные паттерны в большом корпусе. Иными словами, автоматическая разметка используется как *weak labelling*, позволяющий масштабировать анализ, но не заменяющий экспертную кодировку.

3.1.3. Семантическая проверка смешанного нарративного класса

В данном разделе проводится дополнительная проверка интерпретации смешанного нарративного класса, для этого проводится семантическая проверка, где тексты публикаций представляются в виде эмбедингов *multilingual-e5-small*. Ее задача состоит в оценке того, действительно ли смешанный класс занимает промежуточное положение между нарративами престижности и доступности.

Сначала тексты публикаций преобразовываются в векторные представления, затем для двух «полюсов»-классов были рассчитаны усредненные векторы – семантические прототипы нарративов. После этого для каждой публикации вычислялась косинусная близость к прототипу престижности и прототипу доступности. Разница между этими значениями интерпретировалась как положение публикации на условной оси «доступность – престижность».

Результаты говорят о том, что все средние значения косинусной близости довольно высоки, порядка 0,9, это объясняется тематической и форматной однородностью корпуса, где большая часть публикаций относится к тематике вузов. В связи с этим смотреть на абсолютные значения близости не имеет смысла, лучше обратить внимание на направление различий между близостью к двум прототипам. Показатель *access_minus_prestige* помогает увидеть, что

публикации класса «престижность» в среднем оказываются ближе к прототипу престижности, то же справедливо и для «доступности». А вот смешанный класс располагается примерно посередине между прототипами, это подтверждает, что смешанный нарратив не является побочной категорией, а отражает зону пересечения двух нарративных рамок.

Таким образом, семантическая проверка показывает, что смешанный класс не противоречит его интерпретации как промежуточного между доступностью и престижностью. Эти публикации используют одновременно элементы имиджевого позиционирования и практико-информационной коммуникации. Например, в публикации могут описывать статистику приемной кампании через язык достижений и востребованности среди абитуриентов или образовательные возможности через карьерные перспективы и высокий статус учреждения. Это представляется важным для дальнейшей интерпретации, поскольку указывает, что престижность и доступность в коммуникации университетских сообществ в социальной сети не всегда представляются полярными взаимоисключающими нарративами; они, наоборот, могут сочетаться внутри одной публикации.

3.2. Тематико-контекстный анализ корпуса

3.2.1. Тематическое моделирование LDA и контекст доступности высшего образования

Латентное размещение Дирихле (LDA) используется как дополнительный способ описать тематическую структуру корпуса. Словарная разметка отвечает на вопрос, присутствуют ли в тексте маркеры доступности и престижности; LDA же показывает более обширную тематику публикаций: науку, образовательные программы, студенческую жизнь, приемную кампанию, мероприятия, достижения и институциональную коммуникацию. Названия тем присваиваются на основе наиболее весомых слов в каждой теме, то есть LDA используется как инструмент разведочного тематического анализа.

Выделены 6 тем (см. Таблицу 3): «наука, исследования и технологии», «академическое управление и институциональная повестка», «культура, мероприятия, события», «образовательные программы», «приемная кампания, заявки и конкурсы», «достижения, спорт, поздравления».

Тема про спорт, достижения и поздравления имеет самый высокий лайк-рейт. Посты с темой с событиями и приглашениями чаще подвергаются пересылке репостами и написанию комментариев. Посты с научной темой имеют высокую долю вхождений слов-маркеров престижа (0.79 и 0.75). Посты с темой образовательных программ и приемной кампании имеют

Таблица 3 – Результаты LDA: темы и топ-слова.

Id	Название темы	Топ-слова
0	Наука, исследования и технологии	развития, технологий, научно, области, работы, технологии, конференции, которые, науки, научных, проектов, ученых, наука, системы, проекта
1	Академическое управление и институциональная повестка	академии, кафедры, имени, института, факультета, наук, гаугн, образования, ректор, совета, профессор, мид, директор, работе, доцент
2	Культура, мероприятия, события	мастер, имени, искусства, время, пройдет, театра, приглашаем, состоится, misis, выставка, класс, ждем, концерт, москва, октября
3	Образовательные программы	обучения, программы, образования, обучение, подготовки, программа, языка, образование, pushkin, образовательных, программ, вузов, inst, pushkin in...
4	Приемная кампания, заявки и конкурсы	конкурса, конкурс, открытых, дверей, открытых дверей, сайте, конкурсе, онлайн, прием, мифи, пройдет, подать, победителей, участников, заявку
5	Достижения, спорт, поздравления	место, сегодня, поздравляем, которые, жизни, очень, время, мгусит, желаем, победы, наши, спорта, наших, нашей, великой

высокую долю вхождений слов-маркеров доступности (0.61 и 0.67).

При рассмотрении динамики тем в публикациях сквозь года (см. Рисунок 15), можно отметить разный характер изменений публикационной динамики. Доминирующая и растущая тема – публикации поздравительного характера, заявляющие в том числе о достижениях в спорте. Доля таких публикаций стабильно высока и имеет тренд на рост, что может свидетельствовать о стремлении сообществ поддерживать позитивный успешный имидж. Стабильные темы – событийный контент, культурные мероприятия, а также наука, исследования и технологии. Динамика данных тем не имеет выраженных спадов или подъемов, они сохраняют стабильный уровень присутствия. Образовательные программы и приемная кампания – снижающиеся темы, возможными причинами этому можно обозначить перенос анонсов в другие каналы связи, насыщение аудитории и снижение интереса к таким материалам. Институциональная повестка видится растущей, это может отражать усиление позиции коммуникации от лица университета, а также переход к более формальному контенту.




Рисунок 15 — Динамика тем в публикациях в годовом срезе

3.2.2. Анализ контекстного окружения ключевых слов (KWIC)

Данный метод показывает фрагмент текста вокруг частотного термина, что позволяет проверить и интерпретировать словарь маркеров доступности. Например, "бюджетные места", "общежитие", "стипендия" могут встречаться абсолютно в разных контекстах. KWIC позволяет посмотреть контексты использования: в информационной коммуникации в рамках приемной кампании, в вопросах абитуриентов и родителей, в тексте претензий к условиям доступности образования.

Самые частотные словосочетания среди постов с маркерами доступности: "открытых дверей", "прием заявок", "мастер-класс", "приемной комиссии", "подать заявку" — показывают, что нарратив доступности в публикациях оформляется чаще через приемную кампанию и информационные сервисы. Присутствует также и институциональный шум, например "nust misis", "нияу мифи", "академии мид». Это скорее следы информационных источников, чем содержательные темы. Наряду с этим присутствуют научно-административные сочетания, "доцент кафедры", "молодых ученых", "науки высшего". Часть доступности пересекается с официальным административным языком и академической повесткой. Контекст, в котором встречаются ключевые термины: «бюджетные места» практически все из сообщества НИУ ВШЭ, связаны с зачислением. Это наглядный пример процедурной доступности — объясняют, где искать себя в списках, как и когда выйдет приказ и прочее. Сочетание «платное обучение» часто встречается совместно с бесплатным, то есть этот термин цепляет более широкий контекст финансовых условий обучения — платность/бесплатность, скидки, квоты. Комментарии показывают не официальную коммуникацию вуза, а реакцию аудитории: *«иногородний студент из многодетной малообеспеченной семьи в общежитие уже 2й год попасть не может»*, *«Обед*

180 рублей - это хорошо, если стипендия сильно побольше, чем 1900 р.», «Подскажите пожалуйста, а как можно попасть в общежитие? Снимаем уже 7 месяцев 🏠. Очень тяжело

😞», «не одарённые ребята со своими 80+ баллов по каждому предмету не вывозят конкурс.

Для них только целевое обучение.» Под постами доступность превращается в практические вопросы и претензии: бюджетные места, стипендии, стоимость, целевое обучение и прочее.

В официальных постах нарратив доступности представляется чаще как информационно-процедурная повестка: приемная комиссия, дни открытых дверей, бюджетные места. В комментариях же та же тема приобретает более проблемный характер. Пользователи задают вопросы о стоимости обучения, доступности общежития для иногородних, размере стипендий, условиях целевого набора, а также высказывают претензии по тем же вопросам. Таким образом, комментарии позволяют увидеть не только заявляемую доступность образования, но и барьеры его доступности, называемые аудиторией – родителями, студентами и абитуриентами.

3.3. Диагностическое моделирование содержательного отклика

3.3.1. Базовое решение и метрики качества

Этот блок дополняет нарративный анализ. Его задача – проверить, связаны ли признаки, нарративные классы, темы и метаданные постов с вероятностью получить высокий содержательный отклик в комментариях. Целевая переменная рассчитывается на основе показателя `meaningful_comm_clean`, отражающего число содержательных комментариев. Пост относится к положительному классу, если значение этого показателя выше 75-го перцентиля, в данном корпусе этот порог составляет 3,6 содержательных комментария, поэтому положительный класс включает около четверти публикаций. Так мы не просто анализируем средние различия между нарративами, а заодно и проверяем, можно ли выделить признаки, ассоциированные с высоким содержательным откликом, уже наблюдаемым в корпусе. Нарративы рассматриваются не только как способ репрезентации высшего образования, но и как формы коммуникации, которые по-разному связаны с обратной связью от подписчиков.

В модели включаются разные группы признаков: очищенный текст публикации, календарные характеристики, длина текста, число токенов, наличие ссылок, эмодзи, знаков вопроса, плотность маркеров престижности и доступности, нарративный класс, тональность, показатели вовлеченности, доминирующая тема LDA, источник публикации. Текст публикаций представляется с помощью TF-IDF векторизации: учитываются униграммы и биграммы, редкие и слишком частотные термины отфильтровываются, стоп-слова исключаются из словаря.

Числовые признаки предварительно проходят обработку в пайплайне: пропущенные значения заполняются медианой с помощью SimpleImputer, после чего признаки подвергаются стандартизации через StandardScaler. Категориальные признаки кодируются отдельно – пропущенные значения заполняются модой, после чего переменные кодируются с помощью OneHotEncoder. Данные поделены на обучающую и тестовую выборку в соотношении 3:1.

Стратифицированные случай train/test split в данном блоке используется как разведочный baseline: он позволяет сравнить несколько семейств моделей на одинаковых данных и проверить наличие содержательного сигнала по сравнению с наивным классификатором. Для временных данных 2020-2025 годов такое разделение не является достаточной проверкой обобщающей способности модели, поскольку публикации разных лет могут быть связаны общими внешними событиями, стилями коммуникации и особенностями источников. Кроме того, для корректной оценки обобщающей способности модели важно, чтобы TF-IDF-векторизатор обучался только на обучающей выборке. При построении статистики на полном корпусе до разделения на подвыборки возникает утечка информации.

В качестве моделей сравниваются наивный классификатор DummyClassifier, логическая регрессия с TF-IDF признаками, LinearSVC с TF-IDF признаками, дерево решений, случайный лес и метод ближайших соседей. Наличие наивного классификатора необходимо для задания минимального уровня сравнения: такая модель всегда предсказывает наиболее частый класс и не использует содержательную информацию о публикации. Поэтому превосходство остальных моделей позволяет оценить, присутствует ли в признаках содержательный сигнал.

Примечание к используемым далее таблицам: метрики accuracy, balanced accuracy, recall, ROC-AUC, PR-AUC, F1-score, overfit F1 gap – являются безразмерными долями и принимают значения в диапазоне от 0 до 1; показатели MAE и RMSE рассчитаны в единицах преобразованной переменной $\log(1 + \text{meaningful_comm_clean})$.

Результаты показывают (см. Таблицу 4), что модели, использующие текстовые и структурные признаки, превосходят наивный классификатор. Наиболее высокое качество классификации демонстрирует логистическая регрессия с TF-IDF признаками, близкие результаты LinearSVC с TF-IDF подтверждают значимость лексического содержания публикаций. Случайный лес показывает сопоставимое качество при использовании категориальных и инженерных признаков, что указывает на вклад нарративного класса, источника публикации, тональности и других метаданных.

Однако результаты данного блока интерпретируются с осторожностью. Это обусловлено

Таблица 4 – Сравнение работы моделей классификации.

model	test accuracy	test _F1	test precision	test _recall	test roc_auc	test pr_auc	overfit F1 gap
Logistic regression + TF-IDF	0.70	0.52	0.44	0.65	0.75	0.54	0.06
LinearSVC + TF-IDF	0.70	0.51	0.43	0.64	0.74	0.52	0.08
Random Forest	0.71	0.51	0.45	0.59	0.75	0.55	0.04
Decision tree	0.79	0.37	0.69	0.25	0.73	0.53	0.02
KNN	0.77	0.29	0.65	0.19	0.71	0.49	0.71
Dummy most frequent	0.75	0.00	0.00	0.00	0.50	0.25	0.00

тем, что в текущей реализации часть признаков имеет пост-публикационный характер, например, число просмотров становится известно только после публикации и зависит от пользовательской вовлеченности. Кроме того, тематическая модель LDA строится на всем корпусе до разделения данных на обучающую и тестовую выборки, вследствие чего тестовая часть косвенно участвует в формировании пространства тем. Поэтому полученные метрики не следует рассматривать как строгую оценку способности модели заранее прогнозировать реакцию аудитории.

Таким образом, использованные модели выполняют преимущественно диагностическую функцию. Они показывают, что высокий содержательный отклик связан не только с общей видимостью публикации в соцсети, но и с ее текстовым содержанием, нарративной рамкой, тематикой, а также особенностями коммуникации конкретного сообщества университета. Результаты трактуются как разведочное подтверждение ассоциативной связи между признаками публикации и реакций аудитории в комментариях, а не как полноценную проверку прогностической модели.

Коэффициенты регрессии помогают определить, какие признаки связаны с вероятностью того, будет ли у поста высокий отклик содержательными комментариями. Сильными

положительными признаками являются «свои вопросы», «списки», «комментариях», «расскажите», «общезитий». Посты приглашают аудиторию задавать вопросы и писать комментарии или связаны с зачислением, общежитием и чаще получают содержательные отклики. Также есть признаки-источники (сообщества вузов) или признаки-бренды «гитра», «бауманка», «source_nickname_mirea.csv». Похоже, что для отдельных сообществ в данных выше вероятность содержательного отклика как такового. Возможно, это из-за стиля ведения коммуникации сообщества. Сильными негативными признаками являются «спортсмены», «министерства», «университетов». Похоже, что это посты-маркеры более официальной коммуникации, где аудитория меньше вовлекается в содержательный разговор.

Дополнительно к классификационной постановке была построена регрессионная модель количества содержательных комментариев. В качестве целевой переменной использовалось значение очищенных содержательных комментариев `meaningful_comm_clean`, логарифмированное для снижения влияния крайне больших значений и учесть ассиметричное распределение комментариев. В качестве нового наивного решения использовался `DummyRegressor` с медианным прогнозом, с ним сравнивалась регуляризованная линейная модель `Ridge`, использующая признаковое пространство, в которое вошли TF-IDF представления текста, числовые и категориальные признаки, нарративные и тематические признаки. Пайплайн обработки данных идентичен предыдущему этапу. Качество моделей оценивалось с помощью метрик MAE, RMSE и R^2 . Результаты (см. Таблицу 5) показывают, что модель `Ridge` + TF-IDF обладает большей объясняющей способностью в сравнении с наивным прогнозом, демонстрирующим отрицательное значение метрики. Такое значение объясняется тем, что медианная константа может быть лучше по MAE, но хуже среднего значения по MSE, относительно которого рассчитывается R^2 . Регуляризованная линейная модель объясняет порядка 25% вариации логарифмированного числа содержательных комментариев, при этом

Таблица 5 – Сравнение результатов регрессионного моделирования.

model	train_mae	test_mae	train_rmse	test_rmse	train_R2	test_R2	overfit rmse gap
Ridge + TF-IDF	0.58	0.60	0.74	0.77	0.31	0.25	0.03
Dummy median	0.68	0.69	0.91	0.91	-0.05	-0.05	0.01

результат интерпретируется не как строгая оценка прогностической силы модели, а как дополнительное подтверждение связи между характеристиками публикации и интенсивностью содержательного отклика в комментариях.

Проведенный этап анализа показывает, что коммуникация московских университетов в социальной сети «ВКонтакте» организовывается вокруг нескольких устойчивых нарративных и тематических рамок. Наиболее выраженным в корпусе данных оказывается нарратив престижности, связанный с достижениями, рейтингами, международными связями, научной активностью, карьерой. Этот тип публикаций выполняет имиджевую функцию, поддерживая позитивную репрезентацию университета, а также его символический статус в медиапространстве. Нарратив доступности представлен менее автономно, часто возникает в сочетании с элементами престижности. Он связывается с приемной кампанией, стоимостью обучения, бюджетными местами, стипендиями, льготами, квотами, общежитием и информационной поддержкой. В отличие от престижности, доступность оказывается скорее практико-ориентированной коммуникационной рамкой. Такие публикации чаще связаны с репостами, содержательными комментариями и вопросами, поскольку затрагивают условия поступления и обучения.

Анализ комментариев позволяет показать различия между институциональной коммуникацией вузов и реакцией аудитории. В постах доступность оформляется как информационно-процедурная, а в комментариях эта повестка трансформируется в более проблемный формат – вопросы и претензии, связанные с доступностью. Таким образом, комментарии позволяют увидеть не только доступность, которая заявляется университетами в тексте, но и воспринимаемые абитуриентами, студентами и родителями барьеры, ограничивающие доступность образования.

Тематическое моделирование дополняет словарную разметку, структурируя корпус вокруг: науки и технологий, институциональной коммуникации, приемной кампании, культурных событий, образовательных программ, достижений и поздравлений. Нарративы престижности и доступности существуют не изолированно, а пересекаются с более широкими тематиками коммуникаций.

Дополнительно были построены диагностические модели, позволяющие проверить связь между характеристиками публикаций и откликом содержательными комментариями. В рамках разведочного погружения, он показывает, что сформированные признаки связаны с различиями между высокой и низкой комментарийной отзывчивостью. Лексическое содержание публикаций

значимо, поскольку лучшие результаты демонстрируют модели с TF-IDF векторизацией.

3.3.2. Продвинутое решение и метрики качества

На следующем этапе были построены расширенные модели классификации высокого содержательного отклика в комментариях. Ключевым методологическим решением стало разделение моделей на несколько постановок в зависимости от доступного слоя признаков. Модель `post + comment_layer` включает текст публикации, нарративные и метаданные признаки, просмотры, а также признаки наблюдаемого слоя комментариев. Эта постановка является диагностической: она показывает, какие характеристики публикации и возникшего обсуждения связаны с высоким содержательным откликом. Ее нельзя трактовать как прогноз до публикации, поскольку часть признаков формируется после проявления активности аудиторией. Для более строгой проверки дополнительно построены модели `post_only` и `pre_publication`. `Post_only` исключает признаки комментариев, но сохраняет метаданные самой публикации – показатели пользовательской реакции. Наиболее строгая постановка `pre_publication` исключает и слой комментариев, и просмотры, в ней остаются только признаки, доступные до или в момент публикации – текст, источник, календарные данные, нарративная рамка и тональность. Это разделение позволяет не смешивать объяснительную и прогнозную задачи, а оценить вклад разных уровней данных.

Особенно важно, что постановка `post + comment_layer` частично пересекается с логикой целевой переменной: высокий содержательный отклик рассчитывается через очищенное число содержательных комментариев, а в признаки модели входят характеристики уже возникшего слоя комментариев. Включая долю содержательных комментариев. Поэтому высокое качество этой постановки не следует интерпретировать как прогноз до публикации. Это диагностическая модель уже сформировавшегося обсуждения. Наиболее честной прогностической оценкой является постановка до публикации поста, где исключены признаки комментариев и вовлеченности; в ней F1 составляет 0,5.

В качестве моделей сравнивались Dummy-классификатор, логистическая регрессия с TF-IDF, RandomForest, HistGradientBoosting, XGBoost, CatBoost, а также модели на основе усредненных Word2Vec/FastText-векторов. Отдельно проверялись современные мультиязычные эмбединги MiniLm и E5, к которым применялась логистическая регрессия. Для текстового представления в основных моделях использовалась TF-IDF-векторизация с униграммами и биграмммами, числовые и категориальные признаки обрабатывались так же, как и на более ранних этапах – с помощью стандартизации и ONE.

Качество моделей (см. Таблицу 6) оценивалось по нескольким метрикам, однако, из-за того, что положительный класс составляет всего четверть выборки, внимание было обращено на F1 (основная метрика), precision, recall и PR-AUC. Наилучшее качество в диагностической постановке post + comment_layer показала модель HistGradientBoosting (F1=0,75), близкие результаты показали CatBoost (F1=0,74) и XGBoost (F1=0,74). Это подтверждает, что нелинейные модели на инженерных признаках хорошо улавливают связь между характеристиками публикации, источников, нарративной рамкой, просмотрами и уже сформировавшимся слоем комментариев. При исключении слоя комментариев качество ожидаемо снижается, в постановке post_only лучше моделью стала логистическая регрессия с TF-IDF (F1=0,53). В наиболее строгой постановке pre_publication эта же модель показала значение метрики несколько ниже (F1=0,50). Снижение метрик не является ошибкой: оно показывает, что значительная часть объясняющей информации появляется уже после публикаций – в процессе проявления пользователями активности в виде реакций просмотров, лайков и обсуждений в комментариях.

Таблица 6 – Сравнение работы продвинутых моделей в разрезе трех постановок.

feature layer	model	test_F1	test_precision	test_recall	test_roc_auc	test_pr_auc	overfit F1 gap
post + comment_layer	Engineered + HistGradientBoosting	0.75	0.87	0.67	0.93	0.87	0.02
post + comment_layer	Engineered + CatBoost	0.74	0.68	0.82	0.93	0.86	0.01
post + comment_layer	Engineered + XGBoost	0.74	0.67	0.83	0.93	0.86	0.01
post + comment_layer	Engineered + RandomForest	0.72	0.64	0.82	0.92	0.82	0.02
post + comment_layer	Logistic regression + TF-IDF	0.59	0.49	0.73	0.82	0.63	0.06

feature layer	model	test_F1	test_precision	test_recall	test_roc_auc	test_pr_auc	overfit F1 gap
post + comment_layer	Word2Vec + FastText doc avg + LogisticRegression	0.55	0.45	0.72	0.80	0.57	0.00
post_only	Post_only Logistic regression + TF-IDF	0.53	0.45	0.65	0.76	0.55	0.07
pre_publication	Pre_publication Logistic regression + TF-IDF	0.50	0.42	0.61	0.72	0.51	0.08
post_only	Post_only HistGradientBoosting	0.44	0.72	0.31	0.78	0.60	0.04
pre_publication	Pre_publication HistGradientBoosting	0.38	0.75	0.26	0.74	0.56	0.03
post + comment_layer	Dummy most frequent	0.00	0.00	0.00	0.50	0.25	0.00

Дополнительные проверки устойчивости подтверждают этот вывод. При временном разделении данных (см. Таблицу 7), когда обучающую выборку формировали публикации за 2020-2024 годы, а тестовую – за 2025 год, качество также снижалось от постановки к постановке (F1 =

Таблица 7 – Сравнение результатов работы моделей при временном разделении данных.

scheme	model	test_F1	test_precision	test_recall	test_roc_auc	test_pr_auc
train_20-24 test_25	post + comment_layer LogisticRegression + TF-IDF	0.62	0.52	0.77	0.85	0.68
rain_20-24 test_25	post_only LogisticRegression + TF-IDF	0.58	0.51	0.69	0.80	0.62
rain_20-24 test_25	pre_publication LogisticRegression + TF-IDF	0.52	0.44	0.63	0.74	0.54

0,62; 0.58 и 0.52). При кросс-валидации GroupKFold на 5 срезах по источнику публикаций (см. Таблицу 8), F1 составил 0,52, 0,47 и 0,38 для трех постановок соответственно. Это говорит о том, что часть сигнала связана не только с самим текстом, но и со спецификой отдельных сообществ, формирующих особое коммуникационное пространство.

Таблица 8 – Сравнение результатов кросс-валидации для трех признаковых слоев.

scheme	feature layer	F1 mean	F1 std	PR-AUC mean	ROC-AUC mean	balanced accuracy mean
GroupKFold by source_nickname	post + comment_layer	0.52	0.03	0.54	0.77	0.69
GroupKFold by source_nickname	post_only	0.47	0.04	0.45	0.70	0.65
GroupKFold by source_nickname	pre_publication	0.38	0.01	0.36	0.62	0.58

Модели на современных мультязычных эмбедингах показали более скромные результаты работы (см. Таблицу 9). E5-small имеет F1=0,43, у E5-base F1=0,42 и у MiniLM F1=0,4. Это говорит о том, что только один общий семантический вектор текста не превосходит модели, которые используют интерпретируемые признаки нарратива, публикации, вовлеченности и источника. Это значит, что высокий содержательный отклик в комментариях не сводится исключительно к смыслу публикации – он формируется на пересечении темы, коммуникативной рамки, институционального источника и реакции аудитории, предшествующей новому отклику.

Таблица 7 – Сравнение результатов работы эмбединг-моделей.

model	test_F1	test_precision	test_recal_l	test_roc_auc	test_pr_auc	overfit F1 gap
multilingual-e5-small embeddings + LogisticRegression	0.43	0.36	0.53	0.62	0.38	0.09
multilingual-e5-base embeddings + LogisticRegression	0.42	0.35	0.53	0.64	0.39	0.09
MiniLM L12 baseline embeddings + LogisticRegression	0.40	0.32	0.51	0.60	0.35	0.09

Общая визуальная сводка результатов работы моделей по метрике F1 представляется в

виде графика с соответствующим цветовым разделением для различных слоев признаков (см. Рисунок 16). Мы изобразили (см. Рисунок 17) модели в признаковом пространстве F1 – PR-AUC, где наглядно можно увидеть координатное расположение значений метрик моделей в зависимости от признакового слоя и используемым методам.




Рисунок 16 — Сравнение моделей по значению F1 на тестовой выборке




Рисунок 17 — Соотношение F1 и PR-AUC для различных моделей и наборов признаков

образом, продвинутые решения выполняют не только прикладную, но и исследовательскую функцию, показывая, что содержательный отклик в комментариях связан с несколькими слоями данных, а не только с текстом публикации. Диагностические модели демонстрируют высокое

значение объяснительной способности при учете уже наличествующего обсуждения, в то время как постановка `pre_publication` показывает более строгую оценку сигнала, доступного до публикации. Такое разделение позволяет интерпретировать результаты с должной осторожностью: как проверку устойчивых ассоциаций между нарративами, тематикой, источником публикации и содержательной реакцией аудитории, а не как исключительно причинное объяснение или безусловный способ прогнозирования реакций.

3.4. Выводы из анализа данных

В ходе эмпирического анализа были решены несколько взаимосвязанных задач: был подготовлен корпус публикаций сообществ московских университетов в социальной сети «ВКонтакте»; были сконструированы текстовые, нарративные, календарные, поведенческие признаки; был выделен очищенный показатель содержательного отклика в комментариях; была проведена словарная разметка нарративов престижности и доступности, а также было выполнено сравнение публикаций по характеру реакций пользователей. Дополнительно были применены тематическое моделирование, ручная валидация автоматической разметки по правилам и в работе были задействованы несколько типов моделей машинного обучения.

Полученные результаты сообщают о том, что в коммуникации московских университетов наиболее ярко выражается нарратив престижности. Он связан с рейтингами, достижениями, научной активностью, карьерными перспективами, международным сотрудничеством, экспертностью и в целом работает в качестве инструмента позитивной репрезентации университета в медиaprостранстве. Нарратив доступности представлен менее автономно, часто возникает в публикациях, сочетаясь вместе с престижностью. Содержание нарратива связано с приемной кампанией, стоимостью обучения, бюджетными местами, квотами, льготами, общежитием, информационной поддержкой пользователей.

Таким образом, гипотеза о том, что в публичной коммуникации вузов доминирует репутационно-престижный нарратив, эмпирически подтвердилась. При этом анализ реакции аудитории говорит о том, что доступность и престижность выполняют различные коммуникативные функции. «Престижные» публикации чаще поддерживают имиджевое представление и позиционирование университета, в то время как публикации о «доступности» – больше концентрируются на практических вопросах пользователей, что связывается репостами, вопросительными и содержательными комментариями. Эти результаты поддерживают предположение о том, что доступность выступает не только как содержательная тема публикаций, но и как коммуникационная рамка, призывающая к обратной связи подписчиков

сообщества.

Анализ комментариев позволил продемонстрировать различия между тем, как тема подается институционально в тексте публикации и тем, как на нее реагирует аудитория. В текстах публикаций, как уже было обозначено, доступность чаще представляется видом информационно-процедурной повестки, выражаясь в информации о сроках приема, документах, консультациях, днях открытых дверей и т.д.. В комментариях же эта тема приобретает более проблемный характер: пользователи получают возможность обсудить стоимость обучения, общежития, стипендии, конкурсные баллы, льготы, целевой прием и другие барьеры – в располагающей к этому обсуждению среде. Таким образом, слой комментариев позволяет увидеть не только заявляемую университетами доступность получения образования у них, но и то, как аудитория воспринимает барьерные ограничения.

Моделирование высокого содержательного отклика в комментариях позволяет предположить, что реакция аудитории связана не только с общим охватом самой публикации, но и с содержащейся в ней темой, нарративной рамкой, источником и форматом коммуникации в сообществе. При этом в работе специально разводятся разные исследовательские постановки. Диагностическая постановка с признаками комментариев показывает, какие признаки уже наблюдаемого в комментариях обсуждения связаны с высоким откликом. Постановка только с признаками публикации исключает слой комментариев, а наиболее строгая допубликационная постановка моделирует ситуацию, когда постпубликационные признаки (пользовательская вовлеченность) отсутствует, то есть мы имитируем ограничение набора признаков теми данными, которые доступны до учета реакции аудитории. Такое разделение позволяет проводить корректную интерпретацию результатов – не как единый прогноз пользовательской реакции, а как сравнение разных уровней информации о публикации.

Продвинутые модели показали, что наилучшее качество достигается при использовании в анализе инженерных признаков, которые описывают публикацию, нарратив, источник, просмотры и комментарии. Снижение качества в допубликационной постановке является содержательно важным результатом, поскольку показывает, что значительная часть информации о высоком содержательном отклике в комментариях возникает непосредственно после публикации – в процессе того, как распространяется и становится более видимым пост и как формируется обсуждение. Сравнение использования TF-IDF признаков, бустинговых моделей, Word2Vec/FastText и мультязычных эмбеддингов MiniLM и E5 показало, что высокий пользовательский отклик не сводится исключительно к семантике текста – важны

сконструированные признаки коммуникации, реакции аудитории и коммуникационная среда, в которой публикуется материал.

Ручная валидация уточнила границы применимости автоматической разметки признаков. Правила словарей и признаки комментариев следует рассматривать в качестве weak labelling, которые позволяют масштабировать анализ на объемный корпус, но не заменяют экспертную интерпретацию текстов публикаций и комментариев. В связи с этим результаты работы следует воспринимать как анализ устойчивых ассоциативных связей между операционализированными нарративами, тематикой публикаций и пользовательской реакции, но не как фиксированную экспертную классификационную разметку корпуса.

Заключение

Проведенный анализ позволяет увидеть, что нарративы престижности и социальной доступности высшего образования выполняют разные функции в пространстве университетской коммуникации. Престижность связывается преимущественно с символическим позиционированием вуза, имиджевым положением, демонстрацией достижений и поддержанием позитивного образа института. Доступность, в свою очередь, чаще оказывается сопряжена с практическими условиями и информацией, связанной с включенностью в высшее образование и поступлением в учреждение – все это вызывает более содержательную обратную связь со стороны пользователей, которая может выражаться в виде вопросов, реплик, а в иных случаях – в критике и обвинениях.

Главный результат данного исследования состоит в том, что пользовательский отклик нельзя объяснить опираясь исключительно на характеристики охватов или активностью аудитории. Отклик формируется на пересечении нескольких факторов: темы поста, нарративной рамки, источника публикации (поскольку сообщество формирует уникальную коммуникационную среду), формата сообщения-поста и уже возникшего обсуждения в комментариях. Поэтому анализ социальных медиа университетов требует сочетания количественных методов, словарной операционализации, ручной проверки разметки несколькими экспертами и моделей, которые разделяют объяснительную и прогнозную постановки.

Отдельным ограничением исследования является невозможность строго отделить эффект нарративной рамки от внешних событий периода 2020-2025 годов. Рассматриваемый период включает пандемию COVID-19, цифровизацию образовательных процедур, геополитически события 2022 года, санкционные и платформенные ограничения, изменения каналов коммуникации, трансформацию правил приема и образовательной политики. Эти события могли одновременно влиять и на содержание публикаций университетов, и на пользовательскую реакцию. Поэтому результаты работы следует интерпретировать как описание ассоциативных связей в конкретной историко-институциональной ситуации, а не как причинную оценку воздействия нарратива на поведение аудитории.

Результаты анализа позволяют зафиксировать следующий статус гипотез. Гипотеза 1 о том, что в публикациях новостных сообществ московских вузов нарратив престижности представлен чаще, чем нарратив социальной доступности, подтверждена. В корпусе публикаций чаще представлен нарратив престижности, тогда как доступность реже выступает

как самостоятельный класс и нередко включается в смешанные публикации. Гипотеза 2 о тематическом различии нарративов также подтверждена: престижность связана прежде всего с рейтингами, достижениями, научной активностью, карьерными перспективами, международным сотрудничеством и экспертностью, а доступность – с поступлением, бюджетными местами, стоимостью обучения, общежитием, льготами и информационной поддержкой. Гипотеза 3 подтверждена: в публикациях доступность чаще оформляется как процедурно-информационная повестка, тогда как в комментариях она приобретает проблемный характер и связывается с барьерами доступа. Гипотеза 4 подтверждена с оговоркой: публикации о доступности чаще сопровождаются вопросами и содержательными уточнениями, однако размер эффекта по отдельным метрикам умеренный, поэтому результат следует трактовать как устойчивую ассоциативную связь, а не как сильный причинный эффект. Гипотеза 5 подтверждается: публикации с нарративом престижности имеют более позитивную среднюю тональность, чем публикации о доступности ($\text{sentiment_mean} = 0,22$ против $0,10$). Гипотеза 6 частично подтверждена: высокий содержательный отклик связан с темой, нарративной рамкой, источником, форматом публикации и признаками текста, но снижение качества модели в допубликационной постановке показывает, что реакция аудитории не объясняется только семантикой текста до публикации. Таким образом, четыре гипотезы подтверждены, одна подтверждена с оговоркой и еще одна – частично. В целом результаты показывают, что престижность выполняет функцию позитивного символического позиционирования университета, а доступность чаще работает как практико-информационная рамка, вызывающая вопросы, уточнения и обсуждение барьеров.

Перспективы дальнейшего исследования связаны с несколькими направлениями. В первую очередь, можно расширить ручную разметку путем привлечения группы кодировщиков, разработки код-бука для оценки согласованности экспертной разметки признаков. Во-вторых, для более строгой проверки связи признаков публикации с высоким содержательным откликом следует исключить все постпубликационные признаки и проводить все текстовые преобразования исключительно в обучающей подвыборке. В-третьих, можно обратиться к более сложным трансформерным моделям, дообученным на экспертной ручной разметке непосредственно для задачи нарративной классификации и анализа комментариев. Помимо этого перспективным путем развития исследования видится сравнение различных типов университетов, альтернативных каналов коммуникации и более неформальных студенческих сообществ, что позволило бы проверить, насколько выявленные различия между доступностью

и престижностью являются устойчивыми за пределами московских университетов, официальных сообществ и социальной сети «ВКонтакте».

Список использованных источников и литературы

1. Аналитические материалы. Рейтинги университетов 2025. — Текст : электронный // RAEX : [сайт]. — URL: https://raex-rr.com/files/analytics/Analytica_VUZ2025_Web.pdf (дата обращения: 04.02.2026).
2. Арзуманян М. А. Образовательные кредиты: как они меняют ландшафт финансирования высшего образования? //Вестник Томского государственного университета. Экономика. – 2025. – №. 70. – С. 359-375.
3. Бермус А. Г. Проблемы и перспективы постболонского реформирования системы высшего образования в России: теоретический обзор //Педагогика. Вопросы теории и практики. – 2025. – Т. 10. – №. 1. – С. 43-51.
4. Богданов С. В. Воспитание элиты: феномен привилегированного образования в Российской империи конца XIX-начала XX века //Вестник Пермского университета. Серия: История. – 2015. – №. 3 (30). – С. 11.
5. Видясова Л. А. и др. Машинное обучение и NLP в оценке территориальных различий социального самочувствия: комбинированный анализ опросов и данных ВКонтакте //Журнал исследований социальной политики. – 2025. – Т. 23. – №. 4. – С. 725-750.
6. ВКонтакте возглавила рейтинг соцсетей в России по количеству публикаций. — Текст : электронный // РИА Новости : [сайт]. — URL: <https://ria.ru/20250603/vkontakte-2020655885.html> (дата обращения: 07.03.2026)
7. Воронцова Н. Л. Образование как услуга //Актуальные проблемы российского права. – 2020. – №. 4 (113). – С. 59.
8. Высшее образование в России: мониторинг. — Текст : электронный // ВЦИОМ : [сайт]. — URL: <https://wciom.ru/analytical-reviews/analiticheskii-obzor/vysshee-obrazovanie-v-rossii-monitoring> (дата обращения: 10.03.2026).
9. Гавров С. Н., Никандров Н. Д. Образование в процессе социализации личности... // Вестник университета Российской академии образования. – 2008. – №. 5. – С. 21-24.
10. Гневашева В. А.. ВЫСШЕЕ ПРОФЕССИОНАЛЬНОЕ ОБРАЗОВАНИЕ КАК ФАКТОР ПРОФЕССИОНАЛЬНОГО РАЗВИТИЯ СОВРЕМЕННОЙ МОЛОДЕЖИ РОССИИ // Журнал Современные проблемы науки и образования. – 2025. – №. 5. – С. 51-51.
11. Дискин Е. И., Малютин М. Р. МЕССЕНДЖЕР МАХ КАК ИНСТРУМЕНТ МОДЕРНИЗАЦИИ ЭЛЕКТРОННОГО ПРАВИТЕЛЬСТВА: АНАЛИЗ ТРАНСФОРМАЦИИ ВЗАИМОДЕЙСТВИЯ ГРАЖДАН И ГОСУДАРСТВА //Вопросы государственного и

муниципального управления. – 2026. – №. 1. – С. 144-169.

12. Долган Ю. С. СТОИМОСТЬ ОБУЧЕНИЯ КАК ФАКТОР ДОСТУПНОСТИ ВЫСШЕГО ОБРАЗОВАНИЯ //Развитие теории и практики управления социальными и экономическими системами. – 2025. – №. 14. – С. 71-74.

13. Драган Л. Л. Влияние пандемии COVID-19 на реализацию права на образование в Российской Федерации //Закон и право. – 2025. – №. 5. – С. 49-57.

14. Емелина Н. К. и др. Выпускники высшего образования на российском рынке труда: тренды и вызовы //М.: НИУ ВШЭ. – 2022. – С. 37-38.

15. Захаркин Р. А. Концепция вторичной социализации, основанная на идеях П. Бергера и Т. Лукмана, и ее стихийный и целенаправленный аспекты реализации //Общество: социология, психология, педагогика. – 2016. – №. 2. – С. 38.

16. Захаркин Р. А., Ракитина О. С. Тенденции формирования представлений о социальной реальности в условиях информационной перегрузки //Вестник Сургутского государственного педагогического университета. – 2020. – №. 5 (68). – С. 205-216.

17. Зуева О. В. Влияние средств массовой информации на доверие граждан к полиции: стратегии эффективной коммуникации //Вестник Майкопского государственного технологического университета. – 2025. – Т. 17. – №. 1. – С. 118-119.

18. Иткина А. Я. ВЫСШЕЕ ОБРАЗОВАНИЕ: ЦЕЛЬ ИЛИ СРЕДСТВО? //Редакционный совет: профессор АВ Иващенко, профессор НБ Карабущенко, доцент ЕН Полянская, доцент НВ Каргина. – 2015. – С. 95.

19. Как детей участников СВО зачисляют в российские вузы и что об этом думают студенты. — Текст : электронный // Афиша : [сайт]. — URL: <https://daily.afisha.ru/relationship/26179-kak-detey-uchastnikov-svo-zachislyayut-v-rossiyskie-vuzy-i-chto-ob-etom-dumayut-studenty/> (дата обращения: 30.04.2026).

20. Калачев А. В. О содержании понятия «демократизация образования» //Известия Волгоградского государственного педагогического университета. – 2007. – №. 4. – С. 41-45.

21. Луканина М. В., Салиева Л. К. Нарративное манипулирование //Государственное управление. Электронный вестник. – 2014. – №. 46. – С. 217-218.

22. Луначарский А. В., Скрыпник Н. А. Народное образование в СССР в связи с реконструкцией народного хозяйства //Доклады на VII съезде Союза работников просвещения. М., «Работник просвещения. – 1929. – С. 131-132.

23. Малиновский С. С. Региональная дифференциация доступности высшего

образования в России / С. С. Малиновский, Е. Ю. Шибанова. — Текст : непосредственный // Современная аналитика образования. № 13 (43). — М. : НИУ ВШЭ, 2020. — С. 68

24. Названы лучшие регионы по медиаактивности вузов в 2025 году. — Текст : электронный // РИА Новости : [сайт]. — URL: <https://ria.ru/20260324/rejting--2082539761.html> (дата обращения: 25.03.2026)

25. Носкова А. В., Голоухова Д. В., Кузьмина Е. И. Формирование университетской траектории: образовательные мотивы и выборы в нарративах студентов рейтинговых вузов // Высшее образование в России. — 2023. — Т. 32. — №. 12. — С. 88-106.

26. Обзор API ВКонтakte. — Текст : электронный // VK API : [сайт]. — URL: <https://dev.vk.com/ru/api/overview> (дата обращения: 23.04.2026).

27. Попова Э. А. Проблема конструирования социальной реальности в теории массовой коммуникации //ББК 72 я 431 А 43. — 2017. — С. 185.

28. Прахов, И. А. Основные стратегии выбора вуза и барьеры, ограничивающие доступ к высшему образованию : информационный бюллетень / И. А. Прахов, К. В. Рожкова, П. В. Травкин. — М. : НИУ ВШЭ, 2021. — 48 с. — Текст : непосредственный.

29. Прохоров А. В. Управление репутацией вуза и медийные риски //Коммуникативные исследования. — 2022. — Т. 9. — №. 1. — С. 40.

30. Рейтинги вузов. Интегральный рейтинг эффективности коммуникаций. — Текст : электронный // Brand Analytics : [сайт]. — URL: <https://brandanalytics.ru/university-rankings/integral/2025/> (дата обращения: 10.04.2026).

31. РУБЦОВА Л. Э. Теория трехкомпонентной стратификации Вебера //Актуальные исследования. — 2024. — С. 79.

32. Рыбаченко И. А. Анализ технологий автоматизированного извлечения нарратива из текста социальных медиа //Доклады Томского государственного университета систем управления и радиоэлектроники. — 2025. — Т. 28. — №. 1. — С. 100-107.

33. Рысакова П. И. Предмет социологии образования: концепции П. Бурдьё //Известия Российского государственного педагогического университета им. АИ Герцена. — 2007. — Т. 8. — №. 27.

34. Саркисова А. Ю., Петров Е. Ю., Дунаева Д. О. Разработка системы лингвистических маркеров для автоматизированной выгрузки тематических текстовых данных из социальной сети //Государственное управление. Электронный вестник. — 2023. — №. 97. — С. 70-84.

35. Создатель ЕГЭ рассказал, почему экзамен появился в России. — Текст :

электронный // РИА Новости : [сайт]. — URL: <https://ria.ru/20260228/ege-2077449313.html> (дата обращения: 03.03.2026)

36. Соколов А. К. Советская политика в области мотивации и стимулирования труда (1917–середина 1930-х годов) //экономическая история. Обзорение. – 2000. – Т. 4. – С. 39-80.

37. Тимошкин Д. и др. Опыт анализа «цифровых следов» процесса структурной интеграции мигрантов в России с помощью нейросети BERT //Социологическое обозрение. – 2025. – Т. 24. – №. 1. – С. 332-356.

38. Узнать ID страницы или группы ВКонтакте. — Текст : электронный // REGVK : [сайт]. — URL: <https://regvk.com/id/> (дата обращения: 23.04.2026).

39. О внесении изменений в Федеральный закон «Об образовании в Российской Федерации»: федер. закон от 14.07.2022 № 295-ФЗ: [принят Гос. Думой 29 июня 2022 г.; одобрен Советом Федерации 8 июля 2022г.] // Собр. законодательства РФ. – 2022. –№ 29. – Ст. 5262.

40. Об образовании в Российской Федерации: федер. закон от 29.12.2012 № 273-ФЗ: [принят Гос. Думой 21 дек. 2012 г.; одобрен Советом Федерации 26 дек. 2012г.]: ред. От 08.03.2026 // Собр. законодательства РФ. – 2012. –№ 53, ч. 1. – Ст. 7598.

41. Фицпатрик Ш. НК Крупская и народное просвещение: новый подход к ВИ Ленину // Гражданская война в России: Жизнь в эпоху социальных экспериментов и военных испытаний, 1917-1922. – 2020. – С. 238-253.

42. Хруль В. М. Материалистическая феноменология как новый подход к пониманию медиатизации (Рецензия на книгу: Couldry N., Hepp A. The Mediated Construction of Reality. Polity: Cambridge, 2017) //Медиаскоп. – 2018. – №. 3. – С. 18.

43. Широкалова Г. С., Пронина Е. И. Образование как социальный лифт //Вестник Нижегородского университета им. НИ Лобачевского. Серия: Социальные науки. – 2022. – №. 3 (67). – С. 179.

44. Berger, P. L. The social construction of reality: a treatise in the sociology of knowledge / P. L. Berger, T.Luckmann. – New Yourk : Anchor Books, 1966. – 219 p.

45.Blei, D. M. Latent Dirichlet Allocation / D. M& Blei, A. Y. Ng, M. I. Jordan // Journal of Machine Learning Research. – 2003. – Vol. 3. – P. 993-1022.

46.Devlin, J. BERT: Pre-training of deep bidirectional transformers for language understanding / J. Devlin, M.-W. Chang, K. Lee, K. Toutanova // Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language

Technologies. – 2019. – Vol. 1. – P. 4171-4186.

47. Eisenstein, J. What to do about bad language on the internet / J. Eisenstein // Proceedings of the 2013 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. – Atlanta : Association for Computational Linguistics, 2013. – P. 359-369.

48. Grimmer, J. Text as data: The promise and pitfalls of automatic content analysis methods for political texts / J. Grimmer, B. M. Stewart // Political Analysis. – 2013. – Vol. 21., №. 3. – P. 267-297.

49. Kuratov, Y. Adaptation of deep bidirectional multilingual transformers for Russian language / Y. Kuratov, M. Arkhipov // arXiv preprint. – 2019. – arXiv:1905.07213.

50. Pang, B. Opinion mining and sentiment analysis / B. Pang, L. Lee // Foundations and Trends in Information Retrieval& – 2008. – Vol. 2, № 1-2. – P. 1-135.

51. Mikolov, T. Efficient estimation of word representations in vector space / T. Mikolov, K. Chen, G. Corrado, J. Dean // arXiv preprint. – 2013. – arXiv:1301.3781.

Приложения

Приложение А. Ссылка на исследовательский репозиторий.

Исследовательский репозиторий с кодом, промежуточными таблицами и материалами анализа размещен по адресу:

https://github.com/malkovaekaterina/hse_abd_vkr.

Приложение Б. Список источников данных – сообществ университетов г. Москвы.

МГУ имени М.В. Ломоносова, Московский авиационный институт, Высшая школа экономики, РЭУ им. Г.В. Плеханова, МФТИ — Физтех, МИРЭА - Российский технологический университет, РАНХиГС, Университет МИСИС, МГТУ им. Н.Э. Баумана, Российский университет дружбы народов (РУДН), Сеченовский Университет, МГИМО Университет, Финансовый университет при Правительстве РФ, НИЯУ МИФИ, Университет имени О.Е. Кутафина (МГЮА), ГИТИС, Губкинский университет, Российский национальный исследовательский медицинский университет им. Н.И. Пирогова, Университет «МЭИ», Московский педагогический государственный университет, Всероссийский государственный институт кинематографии им. С.А. Герасимова, Московский городской педагогический университет, Российский государственный гуманитарный университет, НИУ МИЭТ, Российский государственный аграрный университет - МСХА им. К.А. Тимирязева, Государственный университет управления, Московский государственный строительный университет, Российский государственный университет им. А.Н. Косыгина, Театральный институт им. Бориса Щукина, Российский химико-технологический университет им. Д.И. Менделеева, Российская академия музыки им. Гнесиных, Московский финансово-промышленный университет «Синергия», Московский Политех, Московский государственный психолого-педагогический университет, МГТУ «СТАНКИН», Московский государственный университет спорта и туризма, Российский государственный социальный университет, Российский биотехнологический университет, Российский университет транспорта, Дипломатическая академия МИД России, Православный Свято-Тихоновский гуманитарный университет, Российский государственный геологоразведочный университет имени Серго Орджоникидзе, Московская государственная академия хореографии, Российский университет спорта «ГЦОЛИФК», РГХПУ им. С.Г. Строганова, Московский институт психоанализа, Московский государственный лингвистический университет, Университет МАДИ, Московская ветеринарная академия им. К.И. Скрябина, Московская государственная консерватория им. П.И.

Чайковского, Московский государственный медико-стоматологический университет им. А.И. Евдокимова, РЭШ, Московский государственный университет геодезии и картографии, Московский финансово-юридический университет, МАРХИ, Институт Пушкина, Школа-студия МХАТ, МГУТУ имени К. Г. Разумовского, Московский технический университет связи и информатики, Государственный университет по землеустройству, Институт кино и телевидения, Всероссийская академия внешней торговли, Государственный академический университет гуманитарных наук, Государственный музыкально-педагогический институт им. М.М. Ипполитова-Иванова, Российский новый университет, Академия акварели и изящных искусств Сергея Андрияки, Институт современного искусства, Институт международных экономических связей, Высшее театральное училище им. М.С.Щепкина, Институт международного права и экономики им. А.С. Грибоедова, Институт театрального искусства, Московский гуманитарный университет, Московский университет им. С.Ю. Витте, Всероссийский государственный университет юстиции, Московский художественно-промышленный институт, МГАХИ им. В.И. Сурикова, Институт мировых цивилизаций, Российский государственный университет правосудия, Московская международная академия, Московский международный университет, Международный юридический институт, Московская высшая школа социальных и экономических наук, Высшая школа сценических искусств, МИТУ-МАСИ, Московский государственный технический университет гражданской авиации, Московский психолого-социальный университет, Московский государственный институт музыки им. А.Г. Шнитке, Российская академия живописи, ваяния и зодчества Ильи Глазунова, Свято-Филаретовский институт, Российская государственная академия интеллектуальной собственности.

Приложение В. Перечень новостных сообщество вузов, включенных в эмпирический корпус исследования.

Таблица В.1 – Перечень новостных сообщество вузов, включенных в эмпирический корпус

source_nickname	group_id	source_nickname	group_id
hse.csv	-25205856	inpsyho.csv	-11290126
mai.csv	-50409684	mslu.csv	-214354323
mgu.csv	-78019879	madi.csv	-138541024
reu.csv	-1177	mgavm.csv	-103477801
mfti.csv	-932	mocsos.csv	-36100537
mirea.csv	-1388	msmsu.csv	-46611574
ranepa.csv	-5398	rash.csv	-471300
misiss.csv	-62258607	miigaik.csv	-44133092
bmstu.csv	-40427933	mfua.csv	-4292
rudn.csv	-1711	marhi.csv	-203483546
sechenov.csv	-65464437	pushkin.csv	-30164925
mgimo.csv	-26555975	mhat.csv	-1010597
fa.csv	-6319	mgutm.csv	-94240017
mephi.csv	-69589815	mtusi.csv	-786
kutafina.csv	-65417	guz.csv	-8990

source_nickname	group_id	source_nickname	group_id
gitis.csv	-145886776	gitr.csv	-32851
gubkin.csv	-71938736	vavt.csv	-194691927
rsmu.csv	-53765914	gaugn.csv	-37520
mpei.csv	-51345945	ippolit.csv	-160773003
mpgu.csv	-30321356	rosnou.csv	-152003
vgik.csv	-199859404	andriaka.csv	-35003319
mgpu.csv	-3983	isi.csv	-26099662
rggu.csv	-16479782	imes.csv	-104797
miet.csv	-33509	shepka.csv	-7555704
timacad.csv	-146300938	iile.csv	-33044983
guu.csv	-23628595	mositi.csv	-71768146
mgsu.csv	-97639426	mosgu.csv	-4456
rguk.csv	-38924	vitte.csv	-58519483
shcukina.csv	-23778827	mhpidesign.csv	-29550550
muctr.csv	-31037181	uwc.csv	-19923410
gnesin.csv	-30431394	rgupru.csv	-212123803
synergy.csv	-38029	mmamos.csv	-84480950
polytech.csv	-33991085	miuniversity.csv	-9003905
mgppu.csv	-38093474	mui.csv	-32026522
stankin.csv	-1332509	shanin.csv	-82402911
mgusit.csv	-30016632	raikin.csv	-59762666
rgsu.csv	-39683739	mitumasi.csv	-29193864
rosbiotech.csv	-168484484	mstuca.csv	-45732330
miit.csv	-159	mpsuru.csv	-180525620
dipacademy.csv	-181211182	shnitke.csv	-60900154
pstgu.csv	-97729	glasunov.csv	-58035731
mgri.csv	-163624433	filaret.csv	-117974920
balletacademy.csv	-211891378	rgiis.csv	-193133254
gtsolifk.csv	-41423	surikov.csv	-194894715
rghpu.csv	-187809308	rpamu.csv	-111837730

Приложение Г. Словари маркеров социальной доступности и престижности.

Для автоматической разметки публикаций использовались словари регулярных выражений. Разметка трактуется как weak labelling: она позволяет масштабировать анализ на большой корпус, но не заменяет ручную классификацию.

Словарь маркеров престижности:

```
prestige_patterns = {
'elite_selective': r'\b(элитн\w*|селективн\w*|отборн\w*|лучши\w*|топ\w*|лидер\w*|конкурсн\w*|ведущ\w*|престиж\w*|рейтинг\w*|перв\w*\s+мест\w*)\b',
'achievement': r'\b(побед\w*|приз\w*|лауреат\w*|награ\w*|преми\w*|медал\w*|финалист\w*|чемпион\w*|успех\w*|успеш\w*|достиген\w*|выигр\w*|триумф\w*|прорыв\w*)\b',
'science': r'\b(научн\w*|исследова\w*|публикац\w*|цитируем\w*|статья\w*|статью\w*|лаборатор\w*|эксперт\w*|инноваци\w*|разработк\w*|технолог\w*|исследовательск\w*\s+грант|грант\s+рнф\w*|рффи|госзадан\w*|патент\w*)\b',
'international_career': r'\b(международн\w*|глобаль\w*|партнер\w*|работодател\w*|карьер\w*|специалист\w*|аккредитац\w*|выпускник\w*)\b' }
```

Словарь маркеров социальной доступности:

```
access_patterns = {
'financial_access': r'\b(бюджет\w*|платн\w*|стоимост\w*|оплат\w*|скидк\w*|стипен\w*|образовательн.{0,20}грант\w*|грант.{0,30}поддержк\w*|льгот\w*|квот\w*|рассроч\w*|кредит\w*|субсид\w*|материальн\w*\s+помощ\w*|социальн\w*\s+лифт\w*)\b',
'procedural_access': r'\b(поступлен\w*|при[ёе]м\w*|егэ\w*|балл\w*|документ\w*|зачислен\w*|конкурсн\w*\s+списк\w*|целев\w*|вступительн\w*|дедлайн\w*|заявлен\w*|
```

```

договор\w*)\b',
'informational_access': r'\b(вебинар\w*|консультац\w*|инструкц\w*|навигатор\w*|
гайд\w*|вопрос\w*|ответ\w*|регистрац\w*|день\w*|открытых\w*|двер\w*|при[ее]мн\w*|
\w*комисс\w*|дод\w*)\b',
'infrastructure_support': r'\b(общезн\w*|кампус\w*|инклузи\w*|доступн\w*|
\w*сред\w*|поддержк\w*|психолог\w*|тьютор\w*|куратор\w*|наставни\w*|адаптац\w*|
помощ\w*\w*студент\w*)\b' }

```

Приложение Д. Используемые модели и библиотеки.

В анализе использовались следующие группы моделей:

Таблица Д.1 – Перечень использованных моделей

Группа методов	Конкретные методы / модели	Назначение
Базовые классификаторы	DummyClassifier; LogisticRegression; LinearSVC; DecisionTreeClassifier; RandomForestClassifier; KNeighborsClassifier	Сравнение качества базовых решений при прогнозировании высокого содержательного отклика аудитории.
Текстовые признаки	TF-IDF с униграммами и биграммами	Построение интерпретируемого числового представления текстов публикаций.
Бустинговые модели	HistGradientBoostingClassifier; CatBoostClassifier; XGBoostClassifier	Проверка нелинейных связей между инженерными признаками публикации и откликом аудитории.
Статические эмбединги	Word2Vec; FastText	Проверка дистрибутивной семантики на уровне усредненных векторных представлений документов.
HuggingFace / transformer embeddings	sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2; intfloat/multilingual-e5-small; intfloat/multilingual-e5-base	Семантическая проверка различий между нарративами престижности и социальной доступности.
Тематическое моделирование	LatentDirichletAllocation	Выделение тематической структуры корпуса публикаций.

В анализе использовались следующие версии библиотек:

Таблица Д.2 – Перечень использованных библиотек

Библиотека	Версия	Библиотека	Версия
Python	3.9	gensim	4.4.0
pandas	2.3.3	catboost	1.2.10
numpy	2.0.2	xgboost	2.1.4
scikit-learn	1.6.1	transformers	4.57.6
scipy	1.13.1	sentence-transformers	5.1.2
matplotlib	3.9.4	torch	2.8.0
plotly	6.7.0	openpyxl	3.1.5

Приложение Е. Словари позитивных и негативных маркеров.

```

positive_pattern = re.compile(
r'\b(успех\w*|лучш\w*|побед\w*|рад\w*|достижен\w*|горд\w*|поздрав\w*|важн\w*|
'благодар\w*|интересн\w*|нов\w*|возможност\w*|вдохнов\w*|
'уникальн\w*|прорыв\w*|поддерж\w*|полезн\w*|сильн\w*|инноваци\w*|успех\w*|
успешн\w*)\b',
flags=re.IGNORECASE,)

negative_pattern = re.compile(

```

```
r'\b(проблем\w*|трудност\w*|сложн\w*|риск\w*|препятств\w*|барьер\w*|дорог\w*|'  
r'недоступн\w*|жалоб\w*|отказ\w*|конфликт\w*|стресс\w*|задерж\w*|ошибк\w*|  
трево\w*|'  
r'нехват\w*|дефиц\w*|скандал\w*|несправедлив\w*|неравн\w*|коррупц\w*|огранич\w*)  
\b',  
flags=re.IGNORECASE,)
```